Impacto de la computación en los bienes raices

El proposito de esta investigacion es evaluar como los avances en la computacion en la ultimas decadas han impactado en las ventas e inversion de bienes raices.

Para evaluar el impacto en una determinada industria, se buscara si es posible encontrar correlaciones y posteriormente, si es posible proyectar regresiones lineales, polinomicas o lineales multiples, de poder realizarse estas regresiones, el coeficiente de estas nos indicara cuanto peso ha tenido una determinada tecnologia sobre la industria seleccionada.

Metodologia

Busqueda de los datasets

Se realizo una busqueda de datasets que contengan registros de productos relacionados a la computacion, se encontraron en total unos 6 datasets obtenidos de wikipedia - cantidad de transistores usando wikitable2csv.ggor.de para extraer las siguientes tablas de datos:

- Memorias Flash.
- FPGA.
- GPU.
- Microprocesadores.
- RAM.
- ROM.

Tambien del worldbank.org se obtuvo los siguientes 3 datasets:

- Porcentaje de la poblacion con internet.
- Poblacion (puede ser de utilidad para normalizar aunque no se llego con el plazo para aplicarlo).
- GDP (puede ser de utilidad para hacer comparaciones aunque no se llego con el plazo para aplicarlo).

Los datasets utilizados para las industrias fueron:

- Ventas de bienes raices (el cual fue completamente analizado) fue obtenido de catalog.data.gov/dataset/real-estate-sales-2001-2018, aunque en la url indique ventas desde el 2001 hasta 2018, en realidad contiene registros hasta el 2020.

Limpieza de los datos

Los datos obtenidos de Wikipedia originalmente tenian monton de irregularidades que son propias de las tablas de esta plataforma, como celdas con referencias a otras paginas, fechas de lanzamiento con formatos inconsistentes, numeros flotantes escritos con commas. Todas estas irregularidades tuvieron que ser eliminadas para poder realizar un posterior analisis.

Por otro lado los datos obtenidos del World Bank Data, como Internet, Poblacion y GDP, poseian como columnas los años y un registro por cada pais, para limpiar estos datasets, primero se filtro el pais de interes y luego se transpuso la tabla para que los valores anuales esten en filas.

Una vez limpios estos datasets relacionados a la computacion, se procedieron a unificar en uno solo fusionados por año.

Analisis exploratorio

Lo primero que se hizo para empezar el analisis fue fusionar los datasets de las industrias que nos interesan, en este caso bienes_raices + computacion.

Luego este dataset fusionado se utilizo para ver si podemos observar correlaciones entre sus columnas mediante un mapa de calor y luego una grafica de pares (pairplot).

Proyeccion de regresiones

Mediante el analisis explotario previo, se procedio a seleccionar un par de las tantas correlaciones encontradas y luego se proyectaron regresiones lineales y polinomicas, tambien se utilizo regresiones lineales multiples para saber con que coeficiente impacto cada una de las tecnologias.

Diagrama resumen de los pasos llevados a cabo

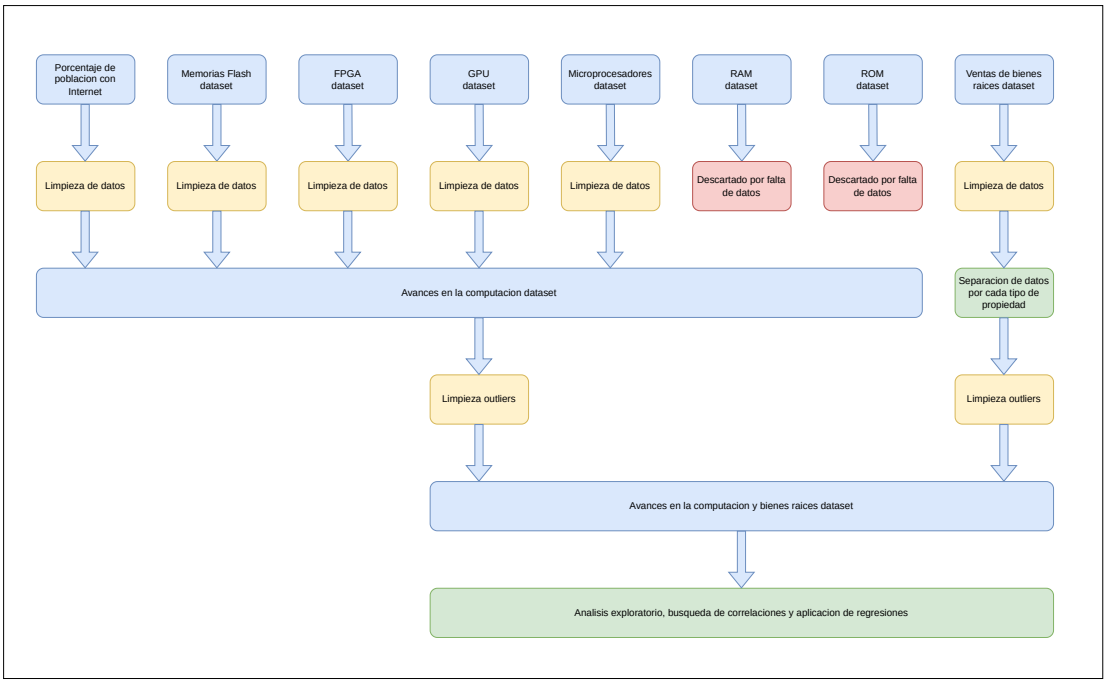

Dependencias

In [ ]:
```
# Standard packages
import pandas as pd
import numpy as np
import re

# Installed packages
from IPython.display import display
from matplotlib import pyplot as plt
%pip install seaborn
import seaborn as sns
from scipy import stats
from sklearn.linear_model import LinearRegression
from sklearn.preprocessing import StandardScaler, PolynomialFeatures
from sklearn.model_selection import train_test_split
from sklearn import metrics
from sklearn.svm import SVR

# Local packages
# NOTE:
#   Evitaremos tener que usar modulos locales externos a
#   este notebook de Jupiter para facilitar el uso en la
#   plataforma Google Colab.
```

```
Defaulting to user installation because normal site-packages is not writ
eable
Requirement already satisfied: seaborn in /home/angrygingy/.local/lib/py
thon3.10/site-packages (0.12.2)
Requirement already satisfied: numpy!=1.24.0,>=1.17 in /home/angryging
y/.local/lib/python3.10/site-packages (from seaborn) (1.23.5)
Requirement already satisfied: pandas>=0.25 in /home/angrygingy/.local/l
ib/python3.10/site-packages (from seaborn) (1.5.3)
Requirement already satisfied: matplotlib!=3.6.1,>=3.1 in /home/angrygin
gy/.local/lib/python3.10/site-packages (from seaborn) (3.7.1)
Requirement already satisfied: contourpy>=1.0.1 in /home/angrygingy/.loc
al/lib/python3.10/site-packages (from matplotlib!=3.6.1,>=3.1->seaborn)
(1.0.7)
Requirement already satisfied: cycler>=0.10 in /home/angrygingy/.local/l
ib/python3.10/site-packages (from matplotlib!=3.6.1,>=3.1->seaborn) (0.1
1.0)
Requirement already satisfied: fonttools>=4.22.0 in /home/angrygingy/.lo
cal/lib/python3.10/site-packages (from matplotlib!=3.6.1,>=3.1->seaborn)
(4.39.3)
Requirement already satisfied: kiwisolver>=1.0.1 in /home/angrygingy/.lo
cal/lib/python3.10/site-packages (from matplotlib!=3.6.1,>=3.1->seaborn)
(1.4.4)
Requirement already satisfied: packaging>=20.0 in /home/angrygingy/.loca
l/lib/python3.10/site-packages (from matplotlib!=3.6.1,>=3.1->seaborn)
(23.0)
Requirement already satisfied: pillow>=6.2.0 in /usr/lib/python3/dist-pa
ckages (from matplotlib!=3.6.1,>=3.1->seaborn) (9.0.1)
Requirement already satisfied: pyparsing>=2.3.1 in /usr/lib/python3/dist
-packages (from matplotlib!=3.6.1,>=3.1->seaborn) (2.4.7)
Requirement already satisfied: python-dateutil>=2.7 in /home/angryging
y/.local/lib/python3.10/site-packages (from matplotlib!=3.6.1,>=3.1->sea
born) (2.8.2)
Requirement already satisfied: pytz>=2020.1 in /usr/lib/python3/dist-pac
kages (from pandas>=0.25->seaborn) (2022.1)
Requirement already satisfied: six>=1.5 in /home/angrygingy/.local/lib/p
ython3.10/site-packages (from python-dateutil>=2.7->matplotlib!=3.6.1,>=
3.1->seaborn) (1.12.0)

[notice] A new release of pip is available: 23.1 -> 23.1.2
[notice] To update, run: pip install --upgrade pip
Note: you may need to restart the kernel to use updated packages.
```

Parametros constantes que utilizaremos

In [ ]:
```python
# Constantes
COLUMNA_FECHA = 'Año'
FECHA_MIN = 2001
FECHA_MAX = 2020
DATASETS_FOLDER = './content'
# Utilizaremos esta para indicar si queremos
# guardar el postprocesado de un dataset,
# util si el dataset original es muy pesado.
GUARDAR_DATOS_PROCESADOS = False

# Global state
poblacion = None # Usado para normalizar los datos
```

Procesando datos relacionados a la industria de la computacion

Como se menciono anteriormente, se procedera a limpiar, extraer las columnas revelantes y fusionar los datasets de `microprocesadores`, `flash`, `fpga`, `gpus`, `ram`, `rom` e `internet`.

Los pasos llevados a cabo durante esta etapa para limpiar los datos de los multiples datasets, provenientes de Wikipedia, por lo general seran:

1. eliminar columnas innecesarias.
2. extraer el año y guardarlo en una columna 'fecha', no tratamos directamente la fecha ya que pueden estar presente de manera inconsistente, sin seguir un formato especifico.
3. remover comas de los numeros flotantes.
4. convertir a flotante las columnas string que representan numeros.
5. filtramos los registros que esten entre un rango de años.
6. solo nos quedamos con los mayores valores de cada año en una determinada columna, ya que solo nos interesa el avance de la technologia, es decir, por ejemplo, la mayor cantidad de transistores.
7. eliminamos valores Nan.

Finalmente fusionamos este dataframe a uno mas general por fecha.

In [ ]:
```
# En esta lista vamos a ir agregando los diferentes dataframes
# que mas adelante fusionaremos en uno solo.
computacion_dfs = []
```

In [ ]:
```
def mantener_columnas(df:pd.DataFrame, columnas:list) -> pd.DataFrame:
    """Mantiene solo las COLUMNAS especificadas en un DF"""
    return df[columnas]

def remover_commas(df:pd.DataFrame, columnas: list) -> pd.DataFrame:
    """Remueve las commas de las COLUMNAS especificadas"""
    for col in columnas:
        df[col] = df[col].str.replace(',', '')
    return df

def convertir_a_flotante(df:pd.DataFrame, columnas:list) -> pd.DataFrame:
    """Convierte las columnas especificadas a flotante"""
    for col in columnas:
        df[col] = pd.to_numeric(df[col], errors='coerce')
    return df

def cortar_agregar_fechas(
        df: pd.DataFrame,
        fecha_column:str=COLUMNA_FECHA,
        min_anio:int=FECHA_MIN,
        max_anio:int=FECHA_MAX
        ) -> pd.DataFrame:
    """Corta un dataframe en un intervalo de tiempo MIN_ANIO-MAX_ANIO esp
    # Create a new dataset with months between min and max
    result = pd.DataFrame()
```

```
    result[fecha_column] = pd.date_range(f'1/1/{min_anio}', f'1/1/{max_an
    result[fecha_column] = result[fecha_column].dt.strftime('%Y-%m-%d')
    result[fecha_column] = pd.to_datetime(result[fecha_column], format='%
    # Merge dataframes
    df[fecha_column] = pd.to_datetime(df[fecha_column], format='%Y-%m-%d'
    result = pd.merge(result, df, on=fecha_column, how='outer')
    # Sort by date
    result = result.sort_values(by=[fecha_column]).reset_index(drop=True)
    #
    result = result.fillna(method='ffill')
    return result

def mantener_mayor_por_fecha(
        df: pd.DataFrame,
        columna_valor:str,
        columna_fecha:str=COLUMNA_FECHA
        ) -> pd.DataFrame:
    """Mantiene solo el valor mas alto por fecha, util cuando queremos ve
       avance de una technologia, solo nos interesa el valor mas alto"""
    df = df.sort_values(by=[columna_fecha, columna_valor], ascending=Fals
    df = df.drop_duplicates(subset=[columna_fecha], keep='first')
    # Back to the original order
    df = df.sort_values(by=[columna_fecha]).reset_index(drop=True)
    return df

def columna_fecha_a_fila(df:pd.DataFrame, pais:str, nueva_columna:str) ->
    """Convierte columnas fecha a fila, filtrando por pais, esto es util
    # Filter rows by country
    df = df[df['Country Name'] == pais]
    # Remove columns that are not a year
    df = df[df.columns[df.columns.str.contains(r'\d{4}')]]
    # Convert columns to rows
    df = df.melt(id_vars=[], var_name=COLUMNA_FECHA, value_name=nueva_col
    return df

def normalizar_con_la_poblacion(df:pd.DataFrame, column:str) -> pd.DataFr
    """Normalizamos una COLUMNA de un dataframe DF con la poblacion"""
    return df ## TODO: fix this
    assert poblacion is not None, 'El dataframe Poblacion no fue cargado'
    df[column] = np.divide(df[column], poblacion['US Population']) * 100
    return df

def fusionar_por_fecha(dataframes:list) -> pd.DataFrame:
    """Fusiona los DATAFRAMES por fecha,
       NOTE: todos los dataframes deben tener la misma cantidad de filas"
    result = pd.DataFrame()
    result[COLUMNA_FECHA] = dataframes[0][COLUMNA_FECHA].unique()
    result[COLUMNA_FECHA] = pd.to_datetime(result[COLUMNA_FECHA], format=
    # Merge dataframes
    for df in dataframes:
        df[COLUMNA_FECHA] = pd.to_datetime(df[COLUMNA_FECHA], format='%Y-
        df = df.sort_values(by=[COLUMNA_FECHA]).reset_index(drop=True)
        df = df.fillna(method='bfill')
        result = pd.merge(result, df, on=COLUMNA_FECHA, how='outer')
    result = result.sort_values(by=[COLUMNA_FECHA]).reset_index(drop=True
    result = result.fillna(method='bfill')
    return result
```

- Memoria Flash

Este dataset presenta las columnas:

- `Chip name` : nombre del chip.
- `Capacity` : capacidad en bits del chip.
- `Flash type` : tipo de memoria flash.
- `FGMOS transistor count` : cantidad de transistores.
- `Date of introduction` : fecha de introduccion.
- `Manufacturer(s)` : fabricante.
- `Process` : tamaño del fabricacion en nm.
- `Area` : area del chip en mm2.
- `Transistor density (tr./mm2)` : dencidad de transistores
- `Ref` : referencia de wikipedia

Solamente nos quedaremos con las columnas "Date of introduction" y "FGMOS transistor count" ya que la cantidad de transistores es una buena manera de medir el avance tecnologico.

In [ ]:
```
flash = pd.read_csv(f'{DATASETS_FOLDER}/flash.csv')
flash.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 24 entries, 0 to 23
Data columns (total 10 columns):
 #   Column                       Non-Null Count  Dtype  
---  ------                       --------------  -----  
 0   Chip name                    24 non-null     object 
 1   Capacity (bits)              24 non-null     object 
 2   Flash type                   24 non-null     object 
 3   FGMOS transistor count       24 non-null     object 
 4   Date of introduction         24 non-null     object 
 5   Manufacturer(s)              24 non-null     object 
 6   Process                      24 non-null     object 
 7   Area                         24 non-null     object 
 8   Transistor density, tr./mm2  24 non-null     object 
 9   Ref                          0 non-null      float64
dtypes: float64(1), object(9)
memory usage: 2.0+ KB
```

Memoria Flash: limpieza

In [ ]:
```
flash = mantener_columnas(flash, ['FGMOS transistor count', 'Date of intr
# Como manejar fechas con multiples formatos: https://stackoverflow.com/a
# Formatos disponibles: https://docs.python.org/3/library/datetime.html#s
fechas1 = pd.to_datetime(flash['Date of introduction'], errors='coerce',
fechas2 = pd.to_datetime(flash['Date of introduction'], errors='coerce',
flash[COLUMNA_FECHA] = fechas1.fillna(fechas2)
flash = flash.drop(columns=['Date of introduction'])
#
flash = remover_commas(flash, ['FGMOS transistor count'])
flash = convertir_a_flotante(flash, ['FGMOS transistor count'])
flash = mantener_mayor_por_fecha(flash, 'FGMOS transistor count')
flash = cortar_agregar_fechas(flash)
flash = flash.fillna(method='bfill')
computacion_dfs.append(flash)
```

Memoria Flash: revision de los datos limpiados

In [ ]:
```
display(flash.describe())
display(flash.tail())
flash.plot(
    x=COLUMNA_FECHA,
    y='FGMOS transistor count',
    title='cantidad de transistores FGMOS a lo largo del tiempo',
    figsize=(4, 2),
    )
plt.show()
```

	FGMOS transistor count
count	2.480000e+02
mean	3.900531e+11
std	6.340693e+11
min	2.621440e+05
25%	1.717987e+10
50%	2.560000e+11
75%	2.560000e+11
max	5.333333e+12

	Año	FGMOS transistor count
243	2019-09-30	2.048000e+12
244	2019-10-31	2.048000e+12
245	2019-11-30	2.048000e+12
246	2019-12-31	2.048000e+12
247	2022-01-01	5.333333e+12

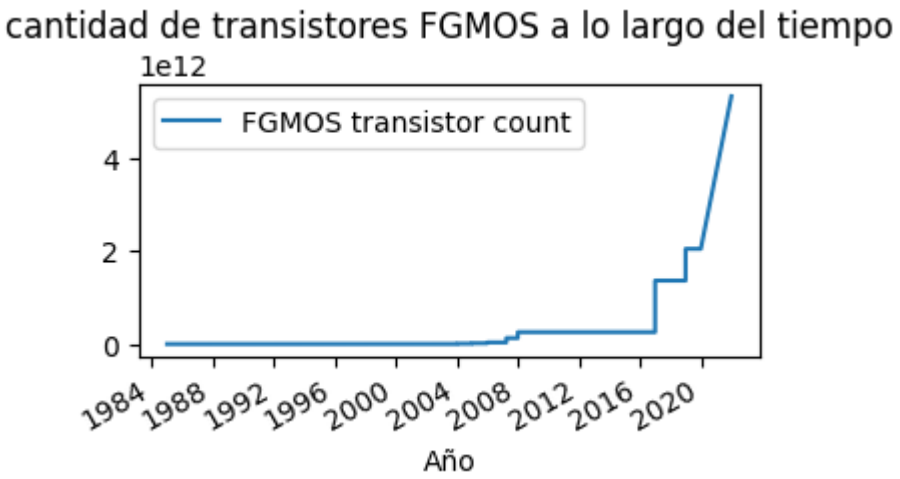

- FPGA (matriz de puertas lógicas programable en campo)

Este dataset presenta las columnas:

- `FPGA` : nombre del modelo de FPGA.

- `Transistor count`: cantidad de transistores.
- `Date of introduction`: fecha de introduccion.
- `Designer`: nombre del diseñador.
- `Manufacturer`: nombre del fabricante.
- `Process`: tamaño de la fabricacion en nm.
- `Area`: area en mm2.
- `Transistor density (tr./mm2)`: dencidad de transistores.
- `Ref`: columna de referencia utilizada en Wikipedia.

De todas estas columnas, al igual que con la memoria Flash, luego de la limpieza solo nos quedaremos con la fecha de introduccion y la cantidad de transistores.

In [ ]:
```
fpga = pd.read_csv(f'{DATASETS_FOLDER}/fpga.csv')
fpga.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 16 entries, 0 to 15
Data columns (total 9 columns):
 #   Column                       Non-Null Count  Dtype
---  ------                       --------------  -----
 0   FPGA                         16 non-null     object
 1   Transistor count             16 non-null     object
 2   Date of introduction         16 non-null     object
 3   Designer                     16 non-null     object
 4   Manufacturer                 11 non-null     object
 5   Process                      13 non-null     object
 6   Area                         3 non-null      object
 7   Transistor density, tr./mm2  3 non-null      object
 8   Ref                          0 non-null      float64
dtypes: float64(1), object(8)
memory usage: 1.2+ KB
```

FPGA: limpieza de los datos

In [ ]:
```
fpga = mantener_columnas(fpga, ['Transistor count', 'Date of introduction
# Pasando cuatrimestres a fecha https://stackoverflow.com/a/53898522/1564
fechas1 = pd.to_datetime(fpga['Date of introduction'], errors='coerce', f
fechas2 = pd.to_datetime(fpga['Date of introduction'], errors='coerce', f
fechas3 = pd.to_datetime(fpga['Date of introduction'], errors='coerce', f
fpga[COLUMNA_FECHA] = fechas1.fillna(fechas2).fillna(fechas3)
fpga = fpga.drop(columns=['Date of introduction'])
#
fpga = remover_commas(fpga, ['Transistor count'])
fpga = convertir_a_flotante(fpga, ['Transistor count'])
fpga = fpga.rename(columns={'Transistor count': 'FPGA transistor count'})
fpga = mantener_mayor_por_fecha(fpga, 'FPGA transistor count')
fpga = cortar_agregar_fechas(fpga)
fpga = fpga.fillna(method='bfill')
computacion_dfs.append(fpga)
```

FPGA: muestreo del dataset limpio

In [ ]:
```
display(fpga.tail())
display(fpga.describe())
fpga.plot(
    x=COLUMNA_FECHA,
```

```
    y='FPGA transistor count',
    title='Cantidad de transistores FPGA a lo largo del tiempo',
    figsize=(4, 2),
    )
plt.show()
```

	Año	FPGA transistor count
234	2019-10-31	5.300000e+09
235	2019-11-30	5.300000e+09
236	2019-12-31	5.300000e+09
237	2020-01-01	3.500000e+10
238	2020-01-01	9.200000e+10

	FPGA transistor count
count	2.390000e+02
mean	3.874770e+09
std	6.532048e+09
min	7.000000e+07
25%	1.000000e+09
50%	2.500000e+09
75%	5.300000e+09
max	9.200000e+10

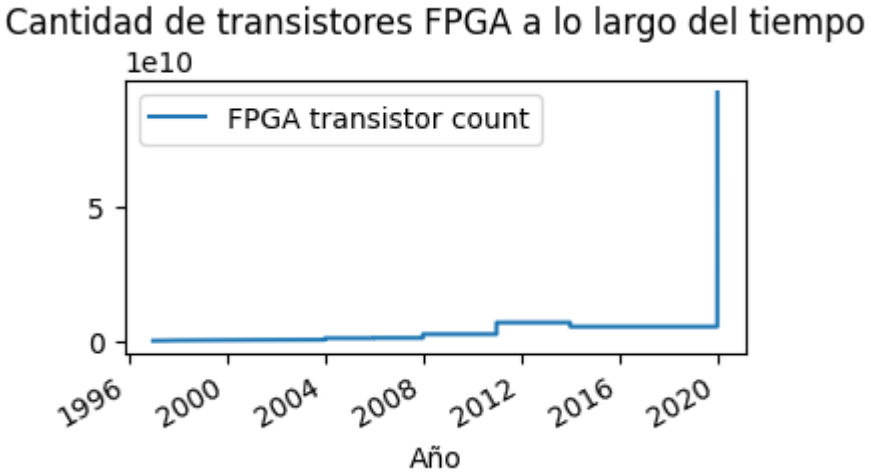

- GPU (unidad de procesamiento gráfico)

Este dataset presenta las columnas:

- `Processor` : nombre del modelo de procesador.
- `Transistor count` : cantidad de transistores.
- `Year` : año de lanzamiento.
- `Designer(s)` : nombre del diseñador.
- `Fab(s)` : nombre del fabricante.
- `Process` : tamaño de la fabricacion en nm.
- `Area` : area en mm2.

- `Transistor density, (tr./mm2)` : dencidad de transistores.
- `Ref` : columna de referencia utilizada en Wikipedia.

De todas estas columnas, al igual que con los anteriores datasets, luego de la limpieza solo nos quedaremos con el año de lanzamiento y la cantidad de transistores.

In [ ]:
```
gpus = pd.read_csv(f'{DATASETS_FOLDER}/gpus.csv')
gpus.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 163 entries, 0 to 162
Data columns (total 9 columns):
 #   Column                      Non-Null Count  Dtype  
---  ------                      --------------  -----  
 0   Processor                   163 non-null    object 
 1   Transistor count            163 non-null    object 
 2   Year                        163 non-null    int64  
 3   Designer(s)                 163 non-null    object 
 4   Fab(s)                      163 non-null    object 
 5   Process                     163 non-null    object 
 6   Area                        163 non-null    object 
 7   Transistor density, tr./mm2  163 non-null    object 
 8   Ref                         0 non-null      float64
dtypes: float64(1), int64(1), object(7)
memory usage: 11.6+ KB
```

GPUs: limpieza del dataset

In [ ]:
```
gpus = mantener_columnas(gpus, ['Transistor count', 'Year'])
# Procesando fecha
gpus[COLUMNA_FECHA] = pd.to_datetime(gpus['Year'], format='%Y')
gpus = gpus.drop(columns=['Year'])
#
gpus = remover_commas(gpus, ['Transistor count'])
gpus = convertir_a_flotante(gpus, ['Transistor count'])
gpus = gpus.rename(columns={'Transistor count': 'GPU transistor count'})
gpus = mantener_mayor_por_fecha(gpus, 'GPU transistor count')
gpus = cortar_agregar_fechas(gpus)
gpus = gpus.fillna(method='bfill')
computacion_dfs.append(gpus)
```

GPUs: muestreo del dataset limpio

In [ ]:
```
display(gpus.tail())
display(gpus.describe())
gpus.plot(
    x=COLUMNA_FECHA,
    y='GPU transistor count',
    title='cantidad de transistores en GPU a lo largo del tiempo',
    figsize=(4, 2),
    )
plt.show()
```

	Año	GPU transistor count
258	2019-12-31	1.030000e+10
259	2020-01-01	5.420000e+10
260	2021-01-01	5.820000e+10
261	2022-01-01	8.000000e+10
262	2023-01-01	1.330000e+10

	GPU transistor count
count	2.630000e+02
mean	6.028366e+09
std	8.969200e+09
min	2.100000e+04
25%	3.210000e+08
50%	3.200000e+09
75%	8.900000e+09
max	8.000000e+10

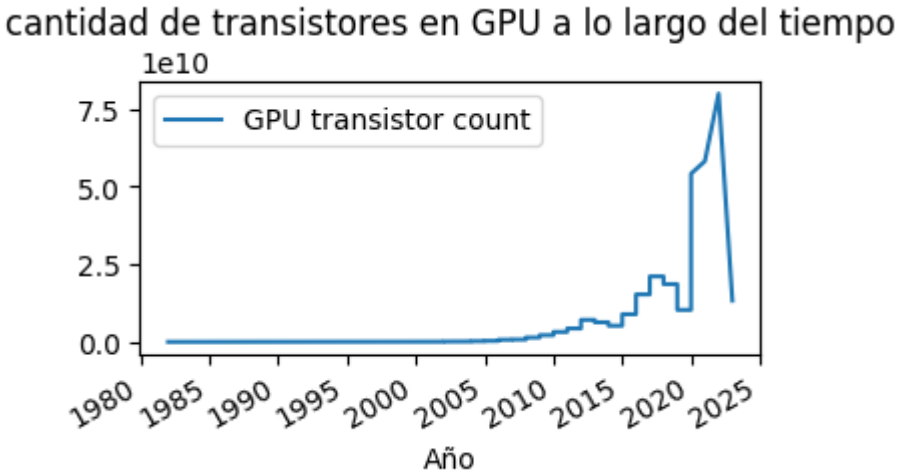

- Microprocesador

Este dataset presenta las columnas:

- `Processor` : nombre del modelo de procesador.
- `Transistor count` : cantidad de transistores.
- `Year` : año de lanzamiento.
- `Designer` : nombre del diseñador.
- `Process (nm)` : tamaño de la fabricacion en nm.
- `Area (mm2)` : area en mm2.
- `Transistor density, tr./mm2` : dencidad de transistores.

De todas las columnas solo nos quedaremos con el año de lanzamiento y la cantidad de transistores.

In [ ]:
```
microprocesadores = pd.read_csv(f'{DATASETS_FOLDER}/microprocessors.csv')
microprocesadores.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 234 entries, 0 to 233
Data columns (total 7 columns):
 #   Column                        Non-Null Count  Dtype
---  ------                        --------------  -----
 0   Processor                     234 non-null    object
 1   Transistor count              234 non-null    object
 2   Year                          234 non-null    object
 3   Designer                      234 non-null    object
 4   Process
(nm)                  234 non-null    object
 5   Area (mm2)                    234 non-null    object
 6   Transistor density, tr./mm2   234 non-null    object
dtypes: object(7)
memory usage: 12.9+ KB
```

Microprocesadores: limpieza del dataset

In [ ]:
```
microprocesadores = mantener_columnas(microprocesadores, ['Transistor cou
#
microprocesadores[COLUMNA_FECHA] = pd.to_datetime(microprocesadores['Year
microprocesadores = microprocesadores.drop(columns=['Year'])
#
microprocesadores = remover_commas(microprocesadores, ['Transistor count'
microprocesadores = microprocesadores[microprocesadores['Transistor count
microprocesadores = convertir_a_flotante(microprocesadores, ['Transistor
microprocesadores = microprocesadores.rename(columns={'Transistor count':
microprocesadores = mantener_mayor_por_fecha(microprocesadores, 'Micropro
microprocesadores = cortar_agregar_fechas(microprocesadores)
microprocesadores = microprocesadores.fillna(method='bfill')
computacion_dfs.append(microprocesadores)
```

Microprocesadores: muestreo del dataset limpio

In [ ]:
```
display(microprocesadores.tail())
display(microprocesadores.describe())
microprocesadores.plot(
    x=COLUMNA_FECHA,
    y='Microprocessor transistor count',
    title='Cantidad de transistores en el Microprocesador a lo largo del
    figsize=(4, 2),
    )
plt.show()
```

	Año	Microprocessor transistor count
276	2019-12-31	3.954000e+10
277	2020-01-01	1.600000e+10
278	2021-01-01	5.700000e+10
279	2022-01-01	1.140000e+11
280	2023-01-01	6.700000e+10

	Microprocessor transistor count
count	2.810000e+02
mean	6.185692e+09
std	1.196830e+10
min	2.500000e+03
25%	4.100000e+08
50%	1.900000e+09
75%	5.560000e+09
max	1.140000e+11

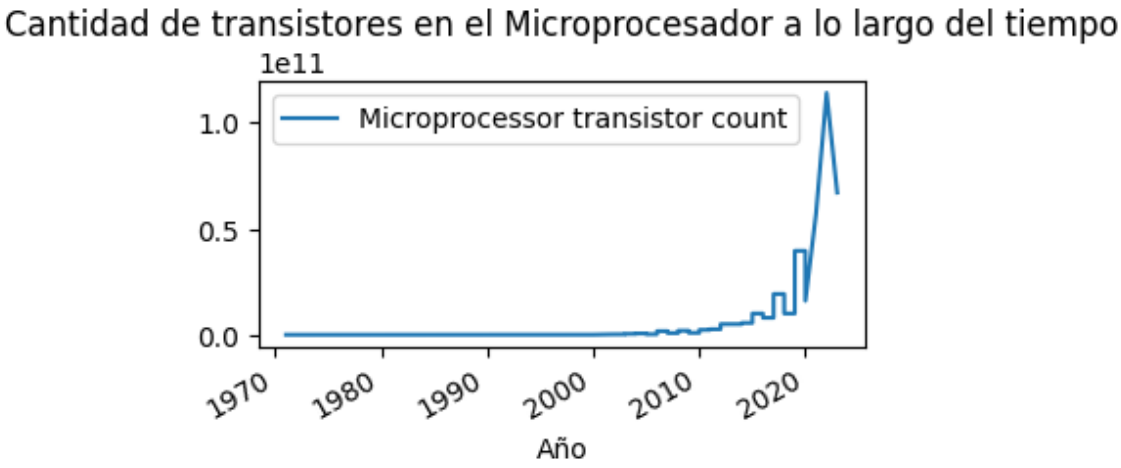

- RAM (memoria de acceso aleatorio)

Este dataset presenta las columnas:

- `Chip name` : nombre del chip.
- `Capacity (bits)` : capacidad en bits del chip.
- `RAM type` : tipo de memoria RAM.
- `Transistor count` : cantidad de transistores.
- `Date of introduction` : fecha de introduccion.
- `Manufacturer(s)` : fabricante.
- `Process` : tamaño de la fabricacion en nm.
- `Area` : area en mm2.
- `Transistor density, tr./mm2` : dencidad de transistores.
- `Ref` : columna de referencia utilizada en Wikipedia.

De todas las columnas solo nos quedaremos con la fecha de introduccion y la cantidad de transistores.

In [ ]:
```
ram = pd.read_csv(f'{DATASETS_FOLDER}/ram.csv')
ram.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 48 entries, 0 to 47
Data columns (total 10 columns):
 #   Column                        Non-Null Count  Dtype
---  ------                        --------------  -----
 0   Chip name                     48 non-null     object
 1   Capacity (bits)               48 non-null     object
 2   RAM type                      48 non-null     object
 3   Transistor count              48 non-null     object
 4   Date of introduction          48 non-null     object
 5   Manufacturer(s)               48 non-null     object
 6   Process                       48 non-null     object
 7   Area                          48 non-null     object
 8   Transistor density, tr./mm2   48 non-null     object
 9   Ref                           0 non-null      float64
dtypes: float64(1), object(9)
memory usage: 3.9+ KB
```

RAM: limpieza del dataset

In [ ]:
```
ram = mantener_columnas(ram, ['Date of introduction', 'Transistor count']
#
fecha1 = pd.to_datetime(ram['Date of introduction'], errors='coerce', for
fecha2 = pd.to_datetime(ram['Date of introduction'], errors='coerce', for
fecha3 = pd.to_datetime(ram['Date of introduction'], errors='coerce', for
ram[COLUMNA_FECHA] = fecha1.fillna(fecha2).fillna(fecha3)
ram = ram.drop(columns=['Date of introduction'])
#
ram = remover_commas(ram, ['Transistor count'])
ram = convertir_a_flotante(ram, ['Transistor count'])
ram = ram.rename(columns={'Transistor count': 'RAM transistor count'})
ram = mantener_mayor_por_fecha(ram, 'RAM transistor count')
ram = cortar_agregar_fechas(ram)
ram = ram.fillna(method='bfill')
# MALO: computacion_dfs.append(ram) este dataset tiene un monton Nan valu
```

RAM: muestreo del dataset limpio

In [ ]:
```
display(ram.tail())
display(ram.describe())
ram.plot(
    x=COLUMNA_FECHA,
    y='RAM transistor count',
    title='Cantidad de transistores en la RAM a lo largo del tiempo',
    figsize=(4, 2),
    )
plt.show()
```

	Año	RAM transistor count
256	2019-09-30	1.374390e+11
257	2019-10-31	1.374390e+11
258	2019-11-30	1.374390e+11
259	2019-12-31	1.374390e+11
260	2019-12-31	1.073742e+09

	RAM transistor count
count	2.610000e+02
mean	2.359537e+10
std	4.077344e+10
min	6.000000e+00
25%	4.294967e+09
50%	8.589935e+09
75%	8.589935e+09
max	1.374390e+11

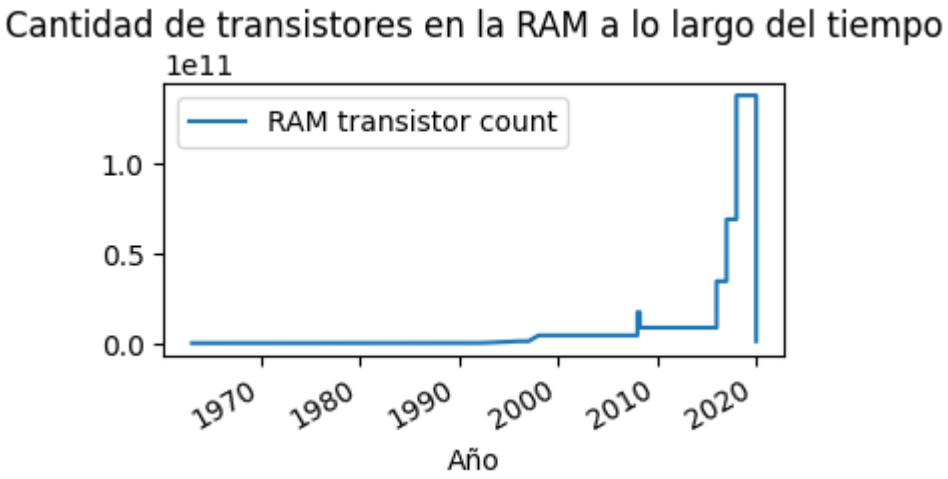

Luego de ver los datos procesados y limpios de la RAM, se puede llegar a la conclusion de que lo mejor seria descartar este dataset ya que tiene demaciados valores Nan

- ROM (memoria de solo lectura)

Este dataset presenta las columnas:

- `Chip name` : nombre del chip.
- `Capacity (bits)` : capacidad en bits del chip.
- `ROM type` : tipo de memoria ROM.
- `Transistor count` : cantidad de transistores.
- `Date of introduction` : fecha de introduccion.
- `Manufacturer(s)` : fabricante.
- `Process` : tamaño de la fabricacion en nm.
- `Area` : area en mm2.
- `Ref` : columna de referencia utilizada en Wikipedia.

De todas las columnas solo nos quedaremos con la fecha de introduccion y la cantidad de transistores.

In [ ]:
```
rom = pd.read_csv(f'{DATASETS_FOLDER}/rom.csv')
rom.tail()
```

Out[ ]:

	Chip name	Capacity (bits)	ROM type	Transistor count	Date of introduction	Manufacturer(s)	Process	Area	Ref
17	27512	512 Kb	EPROM (HMOS)	524,288	1984	Intel	?	?	NaN
18	?	1 Mb	EPROM (CMOS)	1,048,576	1984	NEC	1,200 nm	?	NaN
19	?	4 Mb	EPROM (CMOS)	4,194,304	1987	Toshiba	800 nm	?	NaN
20	?	16 Mb	EPROM (CMOS)	16,777,216	1990	NEC	600 nm	?	NaN
21	?	16 Mb	MROM	16,777,216	1995	AKM, Hitachi	?	?	NaN

ROM: limpieza del dataset

In [ ]:
```
rom = mantener_columnas(rom, ['Date of introduction', 'Transistor count']
#
rom[COLUMNA_FECHA] = pd.to_datetime(rom['Date of introduction'], format='
rom = rom.drop(columns=['Date of introduction'])
#
rom = remover_commas(rom, ['Transistor count'])
rom = convertir_a_flotante(rom, ['Transistor count'])
rom = rom.rename(columns={'Transistor count': 'ROM transistor count'})
rom = mantener_mayor_por_fecha(rom, 'ROM transistor count')
rom = cortar_agregar_fechas(rom)
rom = rom.fillna(method='bfill')
# MALO: computacion_dfs.append(rom) este no tiene suficientes datos valid
```

ROM: muestreo del dataset limpio

In [ ]:
```
display(rom.tail())
display(rom.describe())
rom.plot(
    x=COLUMNA_FECHA,
    y='ROM transistor count',
    title='Cantidad de transsitores en la ROM a lo largo del tiempo',
    figsize=(4, 2),
    )
plt.show()
```

	Año	ROM transistor count
239	2019-08-31	16777216.0
240	2019-09-30	16777216.0
241	2019-10-31	16777216.0
242	2019-11-30	16777216.0
243	2019-12-31	16777216.0

	ROM transistor count
count	2.440000e+02
mean	1.583837e+07
std	3.821991e+06
min	1.024000e+03
25%	1.677722e+07
50%	1.677722e+07
75%	1.677722e+07
max	1.677722e+07

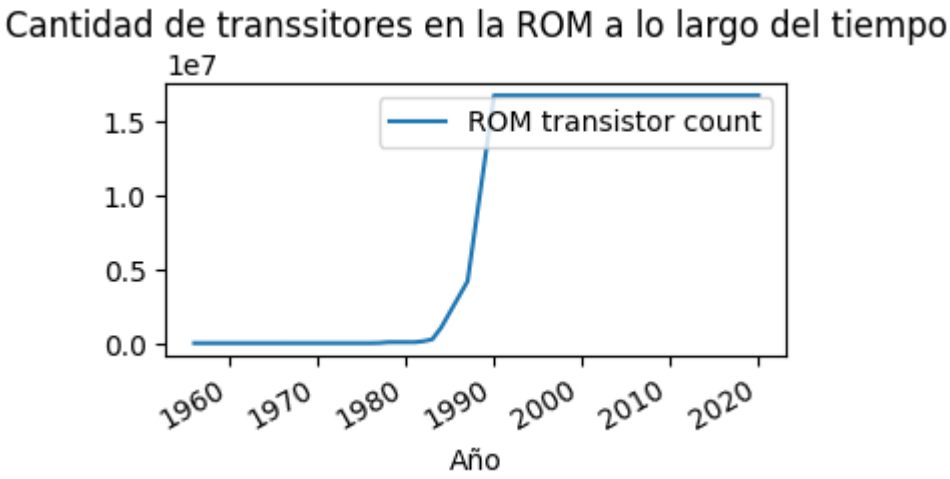

Como observamos en el muestreo de datos luego de la limpieza, al igual que con la RAM, vamos a descartar los datos de la ROM ya que faltan demaciados registros desde el 2000 hasta la actualidad.

- Internet

Este dataset presenta las columnas:

- `Country Name` : nombre del pais.
- `Country Code` : codigo ISO del pais.
- `Indicator Name` : nombre del indicador.
- `Indicator Code` : codigo del indicador.
- `1960, 1961, ..., 2023` : porcentajes de internet por año.

Ya que este dataset fue obtenido del World Bank Data y no tiene irregularidades en los datos, los pasos para procesar a este dataset seran diferentes a los demas:

1. filtramos el pais de interes (Estados Unidos).
2. convertimos las columnas de años en filas.
3. agregamos este dataframe a uno mas general, fusionando por fecha.

In [ ]:
```
internet = pd.read_csv(f'{DATASETS_FOLDER}/theworldbank_internet.csv')
internet.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 266 entries, 0 to 265
Data columns (total 68 columns):
 #   Column          Non-Null Count  Dtype
---  ------          --------------  -----
 0   Country Name    266 non-null    object
 1   Country Code    266 non-null    object
 2   Indicator Name  266 non-null    object
 3   Indicator Code  266 non-null    object
 4   1960            7 non-null      float64
 5   1961            0 non-null      float64
 6   1962            0 non-null      float64
 7   1963            0 non-null      float64
 8   1964            0 non-null      float64
 9   1965            7 non-null      float64
 10  1966            0 non-null      float64
 11  1967            0 non-null      float64
 12  1968            0 non-null      float64
 13  1969            0 non-null      float64
 14  1970            7 non-null      float64
 15  1971            0 non-null      float64
 16  1972            0 non-null      float64
 17  1973            0 non-null      float64
 18  1974            0 non-null      float64
 19  1975            7 non-null      float64
 20  1976            7 non-null      float64
 21  1977            7 non-null      float64
 22  1978            7 non-null      float64
 23  1979            7 non-null      float64
 24  1980            7 non-null      float64
 25  1981            7 non-null      float64
 26  1982            7 non-null      float64
 27  1983            7 non-null      float64
 28  1984            7 non-null      float64
 29  1985            7 non-null      float64
 30  1986            7 non-null      float64
 31  1987            7 non-null      float64
 32  1988            7 non-null      float64
 33  1989            8 non-null      float64
 34  1990            256 non-null    float64
 35  1991            256 non-null    float64
 36  1992            256 non-null    float64
 37  1993            256 non-null    float64
 38  1994            256 non-null    float64
 39  1995            256 non-null    float64
 40  1996            217 non-null    float64
 41  1997            229 non-null    float64
 42  1998            235 non-null    float64
 43  1999            242 non-null    float64
 44  2000            243 non-null    float64
 45  2001            247 non-null    float64
 46  2002            250 non-null    float64
 47  2003            244 non-null    float64
 48  2004            247 non-null    float64
 49  2005            248 non-null    float64
 50  2006            247 non-null    float64
 51  2007            252 non-null    float64
 52  2008            250 non-null    float64
 53  2009            250 non-null    float64
 54  2010            249 non-null    float64
```

```
 55  2011            252 non-null    float64
 56  2012            250 non-null    float64
 57  2013            249 non-null    float64
 58  2014            249 non-null    float64
 59  2015            248 non-null    float64
 60  2016            251 non-null    float64
 61  2017            253 non-null    float64
 62  2018            215 non-null    float64
 63  2019            234 non-null    float64
 64  2020            233 non-null    float64
 65  2021            228 non-null    float64
 66  2022            0 non-null      float64
 67  Unnamed: 67     0 non-null      float64
dtypes: float64(64), object(4)
memory usage: 141.4+ KB
```

Internet: limpieza del dataset

In [ ]:
```
internet = columna_fecha_a_fila(internet, 'United States', 'US internet p
internet[COLUMNA_FECHA] = pd.to_datetime(internet[COLUMNA_FECHA], format=
internet = cortar_agregar_fechas(internet)
computacion_dfs.append(internet)
```

Internet: muestreo del dataset limpio

In [ ]:
```
display(internet.tail())
display(internet.describe())
internet.plot(
    x=COLUMNA_FECHA,
    y='US internet percentage',
    title='Porcentaje de la poblacion con internet en los EEUU a lo largo
    figsize=(4, 2),
    )
plt.show()
```

	Año	US internet percentage
286	2019-11-30	89.430285
287	2019-12-31	89.430285
288	2020-01-01	90.620470
289	2021-01-01	91.753208
290	2022-01-01	91.753208

	US internet percentage
count	261.000000
mean	70.278876
std	15.574419
min	0.784729
25%	67.968053
50%	71.690000
75%	75.000000
max	91.753208

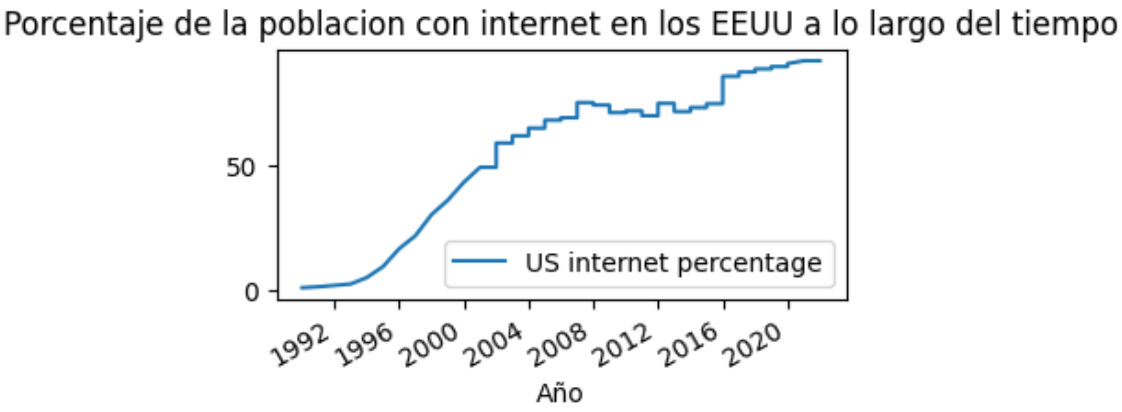

In [ ]:
```
## TODO: agregar dataset relacionado a los telefonos celular.
```

In [ ]:
```
## TODO:
##  agregar dataset relacionado al avance de la IA, tengase en cuenta
##  que el avance de las redes neuronales se pueden medir con la cantidad
##  capas y neuronas utilizadas, mientras que el avance en transformers p
##  medirse con la cantidad de parametros utilizados.
##  Otra manera de medir el avance podria ser mediante la cantidad de pap
```

In [ ]:
```
## TODO: agregar dataset relacionado a la memoria SSD.
```

Unificamos todos los datasets limpios relacionados a la computacion en un solo dataframe y revisamos si se realizo correctamente

In [ ]:
```
computer_advances = fusionar_por_fecha(computacion_dfs)
computer_advances.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 294 entries, 0 to 293
Data columns (total 6 columns):
 #   Column                            Non-Null Count  Dtype
---  ------                            --------------  -----
 0   Año                               294 non-null    datetime64[ns]
 1   FGMOS transistor count            293 non-null    float64
 2   FPGA transistor count             291 non-null    float64
 3   GPU transistor count              294 non-null    float64
 4   Microprocessor transistor count   294 non-null    float64
 5   US internet percentage            293 non-null    float64
dtypes: datetime64[ns](1), float64(5)
memory usage: 13.9 KB
```

Procederemos a remover los outliers, que podrian afectar al analisis exploratorio y a las regresiones.

In [ ]:
```
df_numerico = computer_advances.select_dtypes(include = ["float64"])
#
fig, ax1 = plt.subplots(nrows=1, ncols=1)
bplot = ax1.boxplot(
    df_numerico,
    vert=True,
    patch_artist=True,
    labels=df_numerico.columns,
    flierprops=dict(markerfacecolor='r', marker='D')
    )
```

```
ax1.set_title('Grafico de cajas')
#
for ax in [ax1]:
    ax.yaxis.grid(True)
    ax.xaxis.grid(True)
    ax.set_ylabel('valores')
#
plt.show()
```

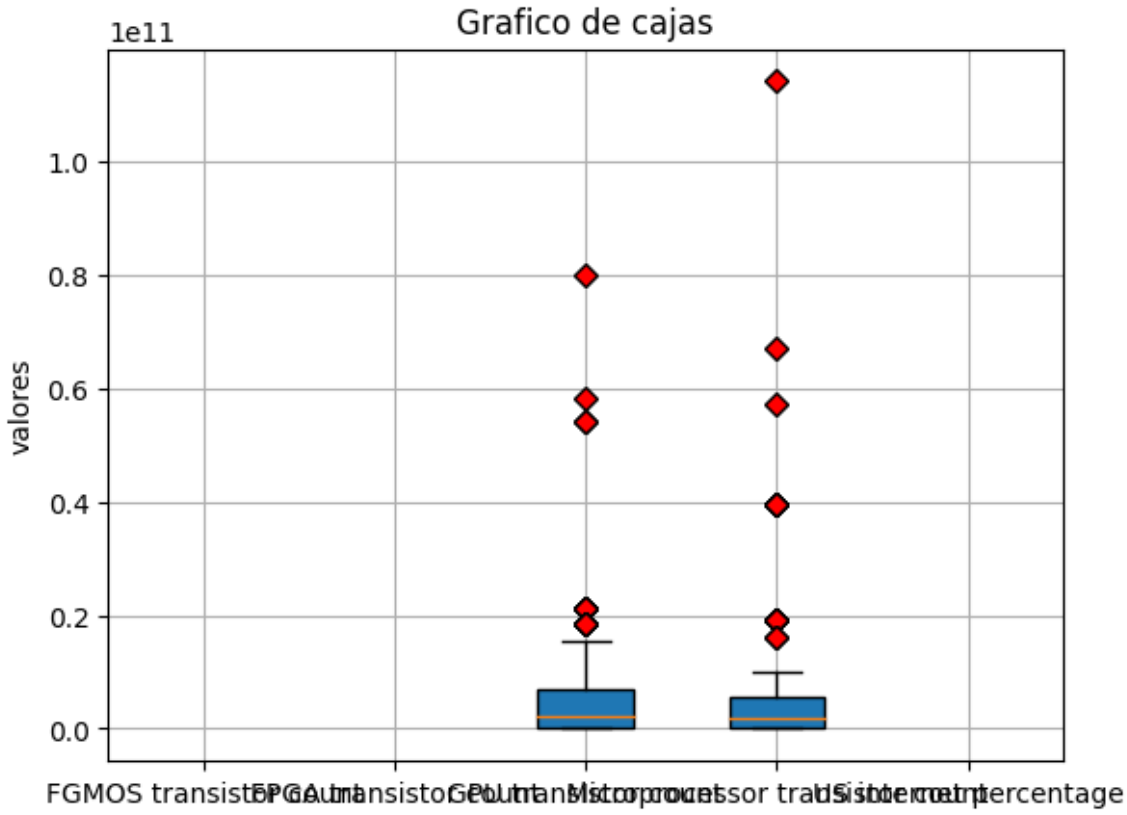

Podemos observar los outliers (puntos rojos sobresaliendo de las lineas de valores atipicos), se reemplazar estos utilizando el metodo de z-score.

In [ ]:
```
threshold = 3
for column in df_numerico.columns:
    zscore = np.abs(stats.zscore(computer_advances[column]))
    computer_advances[column] = np.where(zscore > threshold, np.nan, comp
computer_advances = computer_advances.fillna(method='bfill')
```

Revisando la economia de Estados Unidos

Los datos generales acerca la economia de los Estados Unidos pueden ser de gran ayuda para normalizar o escalar los datos, por ejemplo no es lo mismo el 1% de la poblacion en el 2005 que ese mismo porcentaje en el 2019, tambien puede ayudarnos el GDP para diferenciar si el crecimiento en una industria esta mas relacionada al crecimiento de la economia en general o si es un crecimiento independiente.

- Poblacion

Este dataset presenta las columnas:

- `Country Name` : nombre del pais.
- `Country Code` : codigo ISO del pais.
- `Indicator Name` : nombre del indicador.
- `Indicator Code` : codigo del indicador.
- `1960, 1961, ..., 2023` : poblacion por año.

Este dataset se procesara de la misma manera que como fue tratado el dataset de Internet.

In [ ]:
```
poblacion = pd.read_csv(f'{DATASETS_FOLDER}/theworldbank_population.csv')
poblacion.tail()
```

Out[ ]:

	Country Name	Country Code	Indicator Name	Indicator Code	1960	1961	1962	
261	Kosovo	XKX	Population, total	SP.POP.TOTL	947000.0	966000.0	994000.0	102
262	Yemen, Rep.	YEM	Population, total	SP.POP.TOTL	5542459.0	5646668.0	5753386.0	586
263	South Africa	ZAF	Population, total	SP.POP.TOTL	16520441.0	16989464.0	17503133.0	1804
264	Zambia	ZMB	Population, total	SP.POP.TOTL	3119430.0	3219451.0	3323427.0	343
265	Zimbabwe	ZWE	Population, total	SP.POP.TOTL	3806310.0	3925952.0	4049778.0	417

5 rows × 67 columns

Poblacion: limpieza del dataset

In [ ]:
```
poblacion = columna_fecha_a_fila(poblacion, 'United States', 'US Populati
poblacion[COLUMNA_FECHA] = pd.to_datetime(poblacion[COLUMNA_FECHA], forma
poblacion = cortar_agregar_fechas(poblacion)
```

Poblacion: muestreo del dataset limpio

In [ ]:
```
display(poblacion.tail())
display(poblacion.describe())
poblacion.plot(
    x=COLUMNA_FECHA,
    y='US Population',
    title='Poblacion de US a lo largo del tiempo',
    figsize=(4, 2),
    )
plt.show()
```

	Año	US Population
285	2019-10-31	328329953.0
286	2019-11-30	328329953.0
287	2019-12-31	328329953.0
288	2020-01-01	331501080.0
289	2021-01-01	331893745.0

	US Population
count	2.900000e+02
mean	2.970645e+08
std	3.241652e+07
min	1.806710e+08
25%	2.901079e+08
50%	3.054327e+08
75%	3.183863e+08
max	3.318937e+08

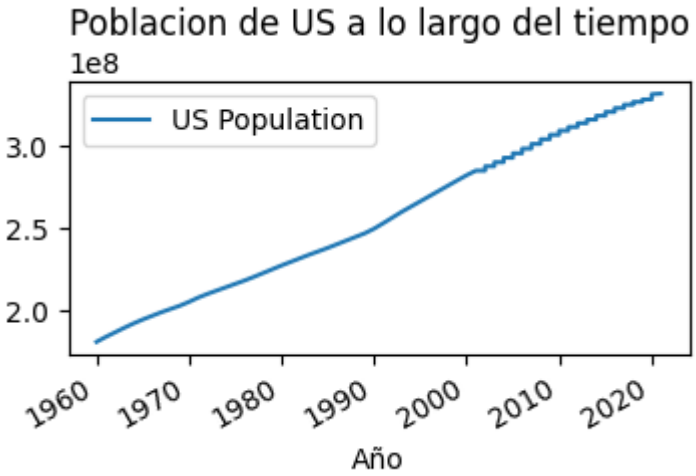

- GDP (producto domestico bruto)

Este dataset presenta las columnas:

- `Country Name` : nombre del pais.
- `Country Code` : codigo ISO del pais.
- `Indicator Name` : nombre del indicador.
- `Indicator Code` : codigo del indicador.
- `1960, 1961, ..., 2023` : GDP por año.

Este dataset se procesara de la misma manera que como fue tratado el dataset de Internet.

In [ ]:
```
gdp = pd.read_csv(f'{DATASETS_FOLDER}/theworldbank_gdp.csv')
gdp.tail()
```

Out[ ]:

	Country Name	Country Code	Indicator Name	Indicator Code	1960	1961	19
261	Kosovo	XKX	GDP (current US$)	NY.GDP.MKTP.CD	NaN	NaN	N
262	Yemen, Rep.	YEM	GDP (current US$)	NY.GDP.MKTP.CD	NaN	NaN	N
263	South Africa	ZAF	GDP (current US$)	NY.GDP.MKTP.CD	8.748597e+09	9.225996e+09	9.813996e+
264	Zambia	ZMB	GDP (current US$)	NY.GDP.MKTP.CD	7.130000e+08	6.962857e+08	6.931429e+
265	Zimbabwe	ZWE	GDP (current US$)	NY.GDP.MKTP.CD	1.052990e+09	1.096647e+09	1.117602e+

5 rows × 67 columns

GDP: limpieza del dataset

In [ ]:
```
gdp = columna_fecha_a_fila(gdp, 'United States', 'US GDP')
gdp[COLUMNA_FECHA] = pd.to_datetime(gdp[COLUMNA_FECHA], format='%Y')
gdp = normalizar_con_la_poblacion(gdp, 'US GDP')
gdp = cortar_agregar_fechas(gdp)
gdp = gdp.fillna(method='bfill')
```

GDP: muestreo del dataset limpio

In [ ]:
```
display(gdp.tail())
display(gdp.describe())
gdp.plot(
    x=COLUMNA_FECHA,
    y='US GDP',
    title='US GDP per 100k people over time',
    figsize=(4, 2),
    )
plt.show()
```

	Año	US GDP
285	2019-10-31	2.138098e+13
286	2019-11-30	2.138098e+13
287	2019-12-31	2.138098e+13
288	2020-01-01	2.106047e+13
289	2021-01-01	2.331508e+13

	US GDP
count	2.900000e+02
mean	1.391798e+13
std	5.194296e+12
min	5.433000e+11
25%	1.145644e+13
50%	1.462396e+13
75%	1.755068e+13
max	2.331508e+13

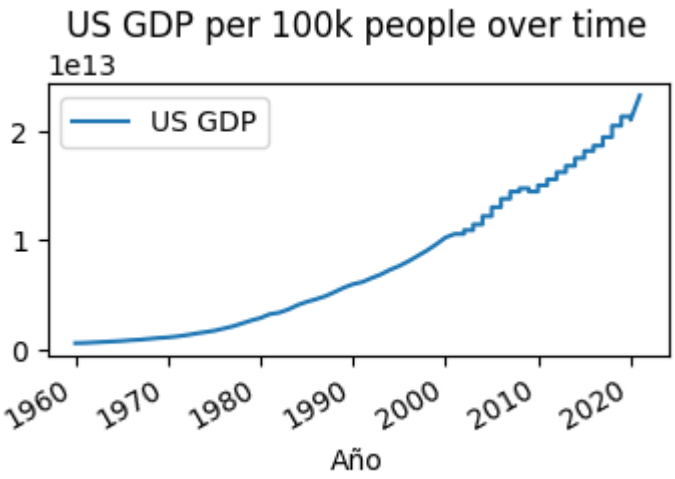

Unificamos todos los datasets procesados y limpios relacionados a la economia, en uno solo

In [ ]:
```
economy = fusionar_por_fecha([gdp, poblacion])
economy.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 290 entries, 0 to 289
Data columns (total 3 columns):
 #   Column         Non-Null Count  Dtype         
---  ------         --------------  -----         
 0   Año            290 non-null    datetime64[ns]
 1   US GDP         290 non-null    float64       
 2   US Population  290 non-null    float64       
dtypes: datetime64[ns](1), float64(2)
memory usage: 6.9 KB
```

Procesando datos relacionado a la industria de los bienes raices

Para analizar esta industria con el mayor de los detalles, se procedera a procesar los datos y almacenar estos resultados en multiples columnas como por ejemplo; "ventas", "inversion", "inversion en propiedades de 1 familia", "inversion en propiedades de 2 familia", etc.

El dataset de bienes raices presenta las siguientes columnas:

- `Date Recorded` : fecha de registro.
- `Sale Amount` : precio al cual se vendio la propiedad en dolares.
- `Property Type` : clasificacion de la propiedad (segun MRC),
- `Residential Type` : clasificacion de la residencia (segun MRC).

Mas informacion acerca la clasificacion de viviendas: Multifamily residential classification.

In [ ]:
```
bienes_raices_ventas = pd.read_csv(f'{DATASETS_FOLDER}/real_estate_sales.
bienes_raices_ventas.info()
```

```
/tmp/ipykernel_130291/1248722542.py:1: DtypeWarning: Columns (2,3) have
mixed types. Specify dtype option on import or set low_memory=False.
  bienes_raices_ventas = pd.read_csv(f'{DATASETS_FOLDER}/real_estate_sal
es.csv')
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 997213 entries, 0 to 997212
Data columns (total 4 columns):
 #   Column            Non-Null Count   Dtype
---  ------            --------------   -----
 0   Date Recorded     997211 non-null  object
 1   Sale Amount       997213 non-null  float64
 2   Property Type     614767 non-null  object
 3   Residential Type  608904 non-null  object
dtypes: float64(1), object(3)
memory usage: 30.4+ MB
```

- Limpieza del dataset de bienes raices

In [ ]:
```
bienes_raices_ventas = mantener_columnas(bienes_raices_ventas, [
    'Date Recorded', 'Sale Amount', 'Property Type', 'Residential Type',
    ])
bienes_raices_ventas[COLUMNA_FECHA] = pd.to_datetime(bienes_raices_ventas
bienes_raices_ventas = bienes_raices_ventas.drop(columns=['Date Recorded'
# Reemplazamos todos los dias por 01 para facilitar agrupar por mes
bienes_raices_ventas[COLUMNA_FECHA] = bienes_raices_ventas[COLUMNA_FECHA]
# Guardamos el dataset ya "limpio" porque Github no admite archivos mayor
if GUARDAR_DATOS_PROCESADOS:
    bienes_raices_ventas.to_csv(f'{DATASETS_FOLDER}/real_estate_sales.csv
```

Bienes raices: muestro del dataset limpio

In [ ]:
```
display(bienes_raices_ventas.tail())
display(bienes_raices_ventas.describe())
```

	Sale Amount	Property Type	Residential Type	Año
997208	53100.0	Single Family	Single Family	2020-06-01
997209	76000.0	Single Family	Single Family	2019-11-01
997210	210000.0	Single Family	Single Family	2020-04-01
997211	280000.0	Single Family	Single Family	2020-06-01
997212	7450000.0	NaN	NaN	2019-12-01

	Sale Amount
count	9.972130e+05
mean	3.911512e+05
std	5.347270e+06
min	0.000000e+00
25%	1.400000e+05
50%	2.250000e+05
75%	3.650000e+05
max	5.000000e+09

- Calculo de la cantidad de ventas por año

Se agrupara por año la cantidad de propiedades vendidas

In [ ]:
```
# "BR" es un acronimo para Bienes Raices
br_ventas_por_anio = pd.DataFrame()
# Agrupar cantidad de ventas por mes
br_ventas_por_anio[COLUMNA_FECHA] = bienes_raices_ventas[COLUMNA_FECHA]
br_ventas_por_anio['re sales'] = bienes_raices_ventas['Sale Amount']
br_ventas_por_anio = br_ventas_por_anio.groupby(COLUMNA_FECHA).size().res
br_ventas_por_anio = br_ventas_por_anio.rename(columns={0: 're sales'})
#
br_ventas_por_anio = cortar_agregar_fechas(br_ventas_por_anio)
br_ventas_por_anio = br_ventas_por_anio.fillna(method='bfill')
br_ventas_por_anio = normalizar_con_la_poblacion(br_ventas_por_anio, 're
```

Muestreo de las ventas por año calculadas

In [ ]:
```
display(br_ventas_por_anio.tail())
display(br_ventas_por_anio.describe())
br_ventas_por_anio.plot(
    x=COLUMNA_FECHA,
    y='re sales',
    title='ventas de bienes raices anual',
    figsize=(4, 2)
    )
plt.show()
```

	Año	re sales
466	2021-05-01	5366.0
467	2021-06-01	6623.0
468	2021-07-01	6441.0
469	2021-08-01	6225.0
470	2021-09-01	5683.0

	re sales
count	471.000000
mean	3998.838641
std	1515.717751
min	1.000000
25%	3043.000000
50%	3848.000000
75%	4957.000000
max	8791.000000

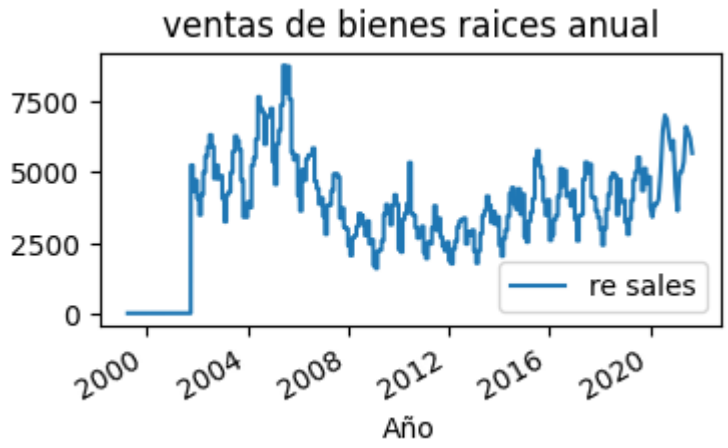

- Calculo de la suma de inversiones por año

Se agrupara por año la suma del valor de las propiedades vendidas

In [ ]:
```
br_inversion_por_anio = pd.DataFrame()
# Agrupar cantidad invertida por mes
br_inversion_por_anio[COLUMNA_FECHA] = bienes_raices_ventas[COLUMNA_FECHA
br_inversion_por_anio['re investment'] = bienes_raices_ventas['Sale Amoun
br_inversion_por_anio = br_inversion_por_anio.groupby(COLUMNA_FECHA).sum(
br_inversion_por_anio = br_inversion_por_anio.rename(columns={0: 're inve
#
br_inversion_por_anio = cortar_agregar_fechas(br_inversion_por_anio)
br_inversion_por_anio = normalizar_con_la_poblacion(br_inversion_por_anio
```

Muestreo de las inversiones por año calculadas

In [ ]:
```
display(br_inversion_por_anio.tail())
display(br_inversion_por_anio.describe())
br_inversion_por_anio.plot(
    x=COLUMNA_FECHA,
    y='re investment',
    title='US real estate total investment per year',
    figsize=(4, 2)
    )
plt.show()
```

	Año	re investment
466	2021-05-01	2.755317e+09
467	2021-06-01	3.522901e+09
468	2021-07-01	4.192108e+09
469	2021-08-01	8.235308e+09
470	2021-09-01	2.745595e+09

	re investment
count	4.710000e+02
mean	1.531054e+09
std	8.128304e+08
min	9.500000e+04
25%	1.072772e+09
50%	1.394021e+09
75%	1.823692e+09
max	8.235308e+09

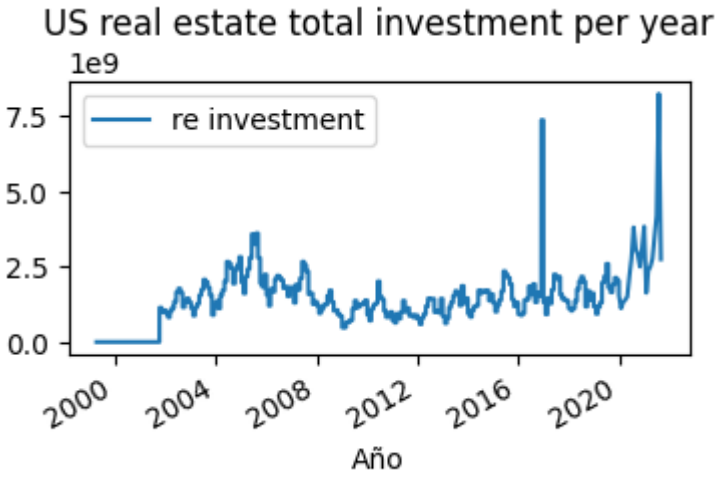

- Calculo de la inversion anual en bienes raices por cada tipo de propiedad y residencia

Se agrupara por cada tipo de propiedad y residencia la suma del valor de las propiedades vendidas anualmente. Podemos observar que poseemos los siguientes tipos de propiedades y residencias:

In [ ]:
```
def obtener_categorias(df:pd.DataFrame, column:str) -> list:
    types = df[column].unique()
    types = [str(x) for x in types]
    return types
def imprimir_categorias(df: pd.DataFrame, column:str) -> None:
    types = obtener_categorias(df, column)
    for i, x in enumerate(types):
        print(f'{i+1}.\t{x}')
```

Tipos de residencias que tenemos presente en el dataset de bienes raices:

In [ ]:
```
imprimir_categorias(bienes_raices_ventas, 'Residential Type')
```

```
1.      nan
2.      Single Family
3.      Condo
4.      Two Family
5.      Three Family
6.      Four Family
```

Tipos de propiedades que tenemos presente en el dataset de bienes raices:

In [ ]:
```
imprimir_categorias(bienes_raices_ventas, 'Property Type')
```

```
1.      Commercial
2.      Residential
3.      Vacant Land
4.      nan
5.      Apartments
6.      Industrial
7.      Public Utility
8.      Condo
9.      Two Family
10.     Three Family
11.     Single Family
12.     Four Family
```

Procederemos a agrupar las ventas en diferentes categorias y las guardamos en columnas separadas

In [ ]:
```
# Eliminamos tipos de propiedades, las cuales hemos visto mas adelante qu
def mantener_typos(df:pd.DataFrame, column:str, typos:list) -> pd.DataFra
    return df[df[column].isin(typos)]
#
typos_propiedades_a_mantener = [
    'Condo', 'Two Family', 'Three Family',
    'Single Family', 'Four Family',
]
bienes_raices_ventas = mantener_typos(bienes_raices_ventas, 'Property Typ
typos_residencias_a_mantener = [
    'Single Family', 'Condo', 'Two Family',
    'Three Family', 'Four Family',
]
bienes_raices_ventas = mantener_typos(bienes_raices_ventas, 'Residential

def agrupar_por_tipo_por_fecha(df:pd.DataFrame, column:str) -> pd.DataFra
    resultado = pd.DataFrame()
    resultado[COLUMNA_FECHA] = bienes_raices_ventas[COLUMNA_FECHA].unique
    resultado = resultado.sort_values(by=COLUMNA_FECHA).reset_index(drop=
    #
    for type in obtener_categorias(df, column):
        new_column_name = f're {type.upper()} investment'
        resultado[new_column_name] = 0
        for year in resultado[COLUMNA_FECHA]:
            sales_amount = df[(df[column] == type) & (df[COLUMNA_FECHA] =
            resultado.loc[resultado[COLUMNA_FECHA] == year, new_column_na
        ## resultado = normalizar_con_la_poblacion(resultado, new_column_
        resultado = resultado.fillna(method='bfill')
    return resultado
```

```
property_types_annual = agrupar_por_tipo_por_fecha(bienes_raices_ventas,
residential_types_annual = agrupar_por_tipo_por_fecha(bienes_raices_venta
```

Muestreo del calculo de ventas por cada tipo de propiedad

In [ ]:
```
display(property_types_annual.tail())
display(property_types_annual.describe())
property_types_annual.plot(
    x=COLUMNA_FECHA,
    y=property_types_annual.columns[1:],
    title='Venta de bienes raices por tipo de propiedad a lo largo del ti
    )
plt.legend(bbox_to_anchor=(1.05, 1), loc='upper left', borderaxespad=0.)
plt.show()
```

	Año	re CONDO investment	re TWO FAMILY investment	re THREE FAMILY investment	re SINGLE FAMILY investment	re FOUR FAMILY investment
180	2020-05-01	1.465843e+08	37723926.0	15326388	1.190297e+09	1515500
181	2020-06-01	1.805396e+08	46021780.0	21284078	1.653826e+09	3774000
182	2020-07-01	2.480436e+08	45813184.0	22237925	2.189361e+09	3447000
183	2020-08-01	2.840804e+08	64472836.0	26545590	2.604900e+09	159734200
184	2020-09-01	2.965516e+08	71996794.0	43251371	2.447775e+09	11784500

	re CONDO investment	re TWO FAMILY investment	re THREE FAMILY investment	re SINGLE FAMILY investment	re FOUR FAMILY investment
count	1.850000e+02	1.850000e+02	1.850000e+02	1.850000e+02	1.850000e+02
mean	1.482781e+08	2.841281e+07	1.223526e+07	8.434162e+08	3.652571e+06
std	1.713453e+08	1.488639e+07	7.159105e+06	4.442826e+08	1.177958e+07
min	0.000000e+00	0.000000e+00	0.000000e+00	0.000000e+00	0.000000e+00
25%	9.964680e+07	1.911991e+07	8.017924e+06	5.724845e+08	1.464554e+06
50%	1.405474e+08	2.762643e+07	1.115005e+07	8.565862e+08	2.260000e+06
75%	1.767243e+08	3.772393e+07	1.532639e+07	1.066808e+09	3.472000e+06
max	2.248216e+09	7.199679e+07	4.325137e+07	2.604900e+09	1.597342e+08

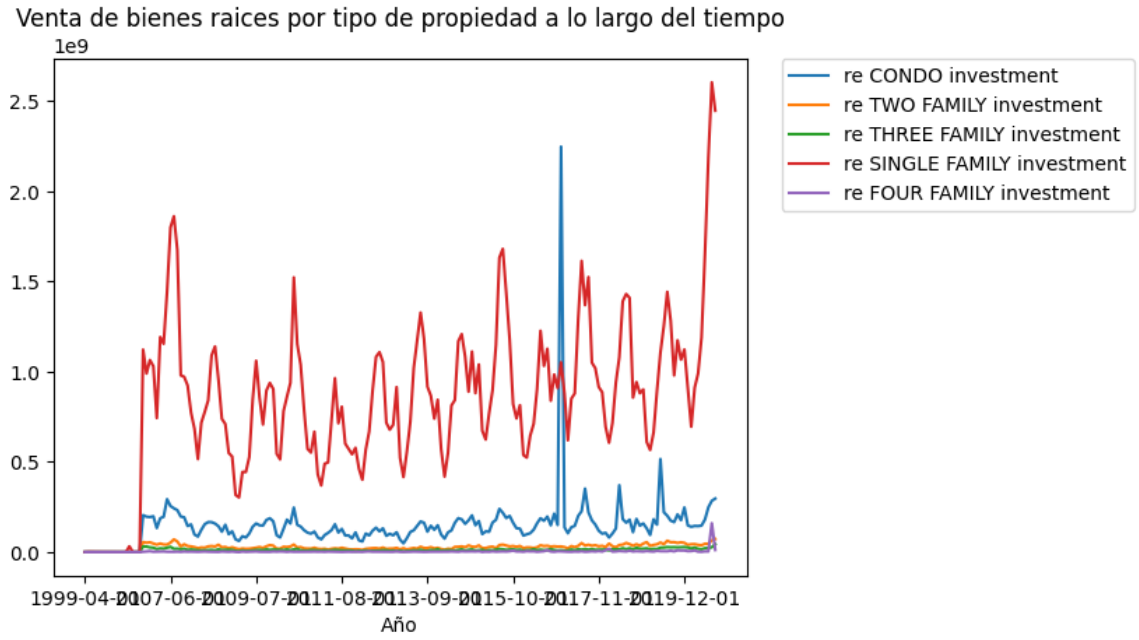

Muestreo del calculo de ventas por cada tipo de residencia

In [ ]:
```
display(residential_types_annual.tail())
display(residential_types_annual.describe())
residential_types_annual.plot(
    x=COLUMNA_FECHA,
    y=residential_types_annual.columns[1:],
    title='Venta de bienes raices por tipo de residencia a lo largo del t
    )
plt.legend(bbox_to_anchor=(1.05, 1), loc='upper left', borderaxespad=0.)
plt.show()
```

	Año	re CONDO investment	re TWO FAMILY investment	re THREE FAMILY investment	re SINGLE FAMILY investment	re FOUR FAMILY investment
180	2020-05-01	1.465843e+08	37723926.0	15326388	1.190297e+09	1515500
181	2020-06-01	1.805396e+08	46021780.0	21284078	1.653826e+09	3774000
182	2020-07-01	2.480436e+08	45813184.0	22237925	2.189361e+09	3447000
183	2020-08-01	2.840804e+08	64472836.0	26545590	2.604900e+09	159734200
184	2020-09-01	2.965516e+08	71996794.0	43251371	2.447775e+09	11784500

	re CONDO investment	re TWO FAMILY investment	re THREE FAMILY investment	re SINGLE FAMILY investment	re FOUR FAMILY investment
count	1.850000e+02	1.850000e+02	1.850000e+02	1.850000e+02	1.850000e+02
mean	1.482781e+08	2.841281e+07	1.223526e+07	8.434162e+08	3.652571e+06
std	1.713453e+08	1.488639e+07	7.159105e+06	4.442826e+08	1.177958e+07
min	0.000000e+00	0.000000e+00	0.000000e+00	0.000000e+00	0.000000e+00
25%	9.964680e+07	1.911991e+07	8.017924e+06	5.724845e+08	1.464554e+06
50%	1.405474e+08	2.762643e+07	1.115005e+07	8.565862e+08	2.260000e+06
75%	1.767243e+08	3.772393e+07	1.532639e+07	1.066808e+09	3.472000e+06
max	2.248216e+09	7.199679e+07	4.325137e+07	2.604900e+09	1.597342e+08

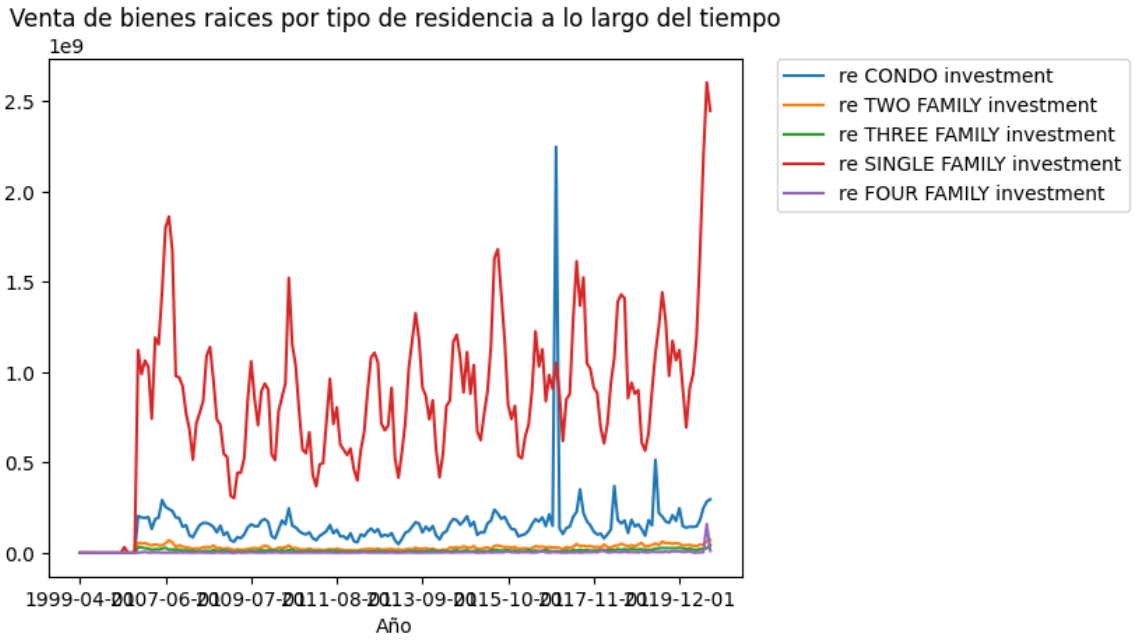

Las ventas de bienes raices residenciales seran descartadas ya que es muy similar a las ventas de propiedades. Realizar el analisis con estos datos serian como duplicar la informacion.

Procederemos a agrupar los diferentes columnas que obtuvimos del procesamiento y las unificamos en un mismo dataset

In [ ]:
```
bienes_raices = fusionar_por_fecha([
    br_ventas_por_anio, property_types_annual, br_inversion_por_anio,
    ])
bienes_raices.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 471 entries, 0 to 470
Data columns (total 8 columns):
 #   Column                        Non-Null Count  Dtype
---  ------                        --------------  -----
 0   Año                           471 non-null    datetime64[ns]
 1   re sales                      471 non-null    float64
 2   re CONDO investment           459 non-null    float64
 3   re TWO FAMILY investment      459 non-null    float64
 4   re THREE FAMILY investment    459 non-null    float64
 5   re SINGLE FAMILY investment   459 non-null    float64
 6   re FOUR FAMILY investment     459 non-null    float64
 7   re investment                 471 non-null    float64
dtypes: datetime64[ns](1), float64(7)
memory usage: 29.6 KB
```

Procedemos revisar si encontramos outliers en los datos de bienes raices

In [ ]:
```
df_numerico = bienes_raices.select_dtypes(include = ["float64"])
#
fig, ax1 = plt.subplots(nrows=1, ncols=1)
bplot = ax1.boxplot(
    df_numerico,
    vert=True,
    patch_artist=True,
    labels=df_numerico.columns,
    flierprops=dict(markerfacecolor='r', marker='D')
    )
ax1.set_title('Grafico de cajas')
#
for ax in [ax1]:
    ax.yaxis.grid(True)
    ax.xaxis.grid(True)
    ax.set_ylabel('valores')
#
plt.show()
```

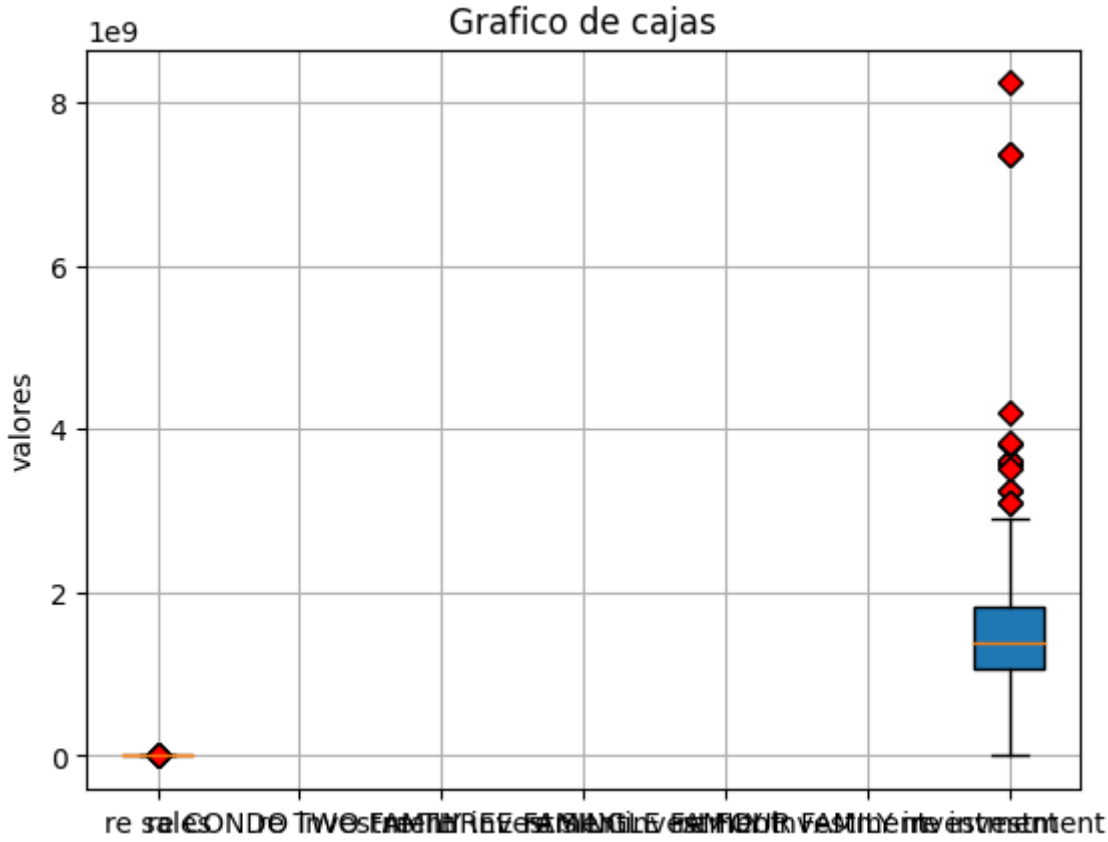

Podemos observar que existen outliers en los datos de bienes raices (puntos rojos), procedemos a remover estos puntos utilizando el metodo de z-score.

In [ ]:
```
threshold = 3
for column in df_numerico.columns:
    zscore = np.abs(stats.zscore(bienes_raices[column]))
    bienes_raices[column] = np.where(zscore > threshold, np.nan, bienes_r
bienes_raices = bienes_raices.fillna(method='bfill')
```

Analizando el impacto de los avances de la computacion en las ventas de bienes raices

A continuacion analizaremos los datos de los avances en computacion y de bienes raices para ver si encontramos alguna correlacion y si logramos poder proyectar alguna regresion.

Ignoraremos las correlaciones que existan entre columnas propias de la computacion o de los bienes raices, es decir por ejemplo: alguna correlacion entre la cantidad de transistores en los Microprocesadores y la cantidad de transistores en las GPU, esto es debido a que solo nos interesa como afecta una industria a otra, no a si misma.

- Unificacion de las columnas de avances en computacion y avances en bienes raices

In [ ]:
```
computacion_y_bienes_raices = fusionar_por_fecha([computer_advances, bien
computacion_y_bienes_raices = computacion_y_bienes_raices.fillna(method='
computacion_y_bienes_raices = cortar_agregar_fechas(computacion_y_bienes_
```

```
numeric_df = computacion_y_bienes_raices.select_dtypes(include=['float64'
columns_to_analize_correlation = numeric_df.columns
```

- Analizando correlaciones entre la computacion y bienes raices

Procederemos a buscar correlaciones entre las columnas relacionadas a la computacion y las columnas relacionadas a los bienes raices, para ver si es posible proyectar alguna regresion.

In [ ]:
```
corr = computacion_y_bienes_raices.corr(method='pearson')
plt.subplots(figsize=(12,8))
sns.heatmap(
    corr,
    xticklabels=columns_to_analize_correlation,
    yticklabels=columns_to_analize_correlation,
    annot=True,
    fmt='.0%',
    cmap=sns.diverging_palette(240, 10, as_cmap=True)
    )
```

```
/tmp/ipykernel_130291/2886285098.py:1: FutureWarning: The default value
of numeric_only in DataFrame.corr is deprecated. In a future version, it
will default to False. Select only valid columns or specify the value of
numeric_only to silence this warning.
  corr = computacion_y_bienes_raices.corr(method='pearson')
```

Out[ ]: <Axes: >

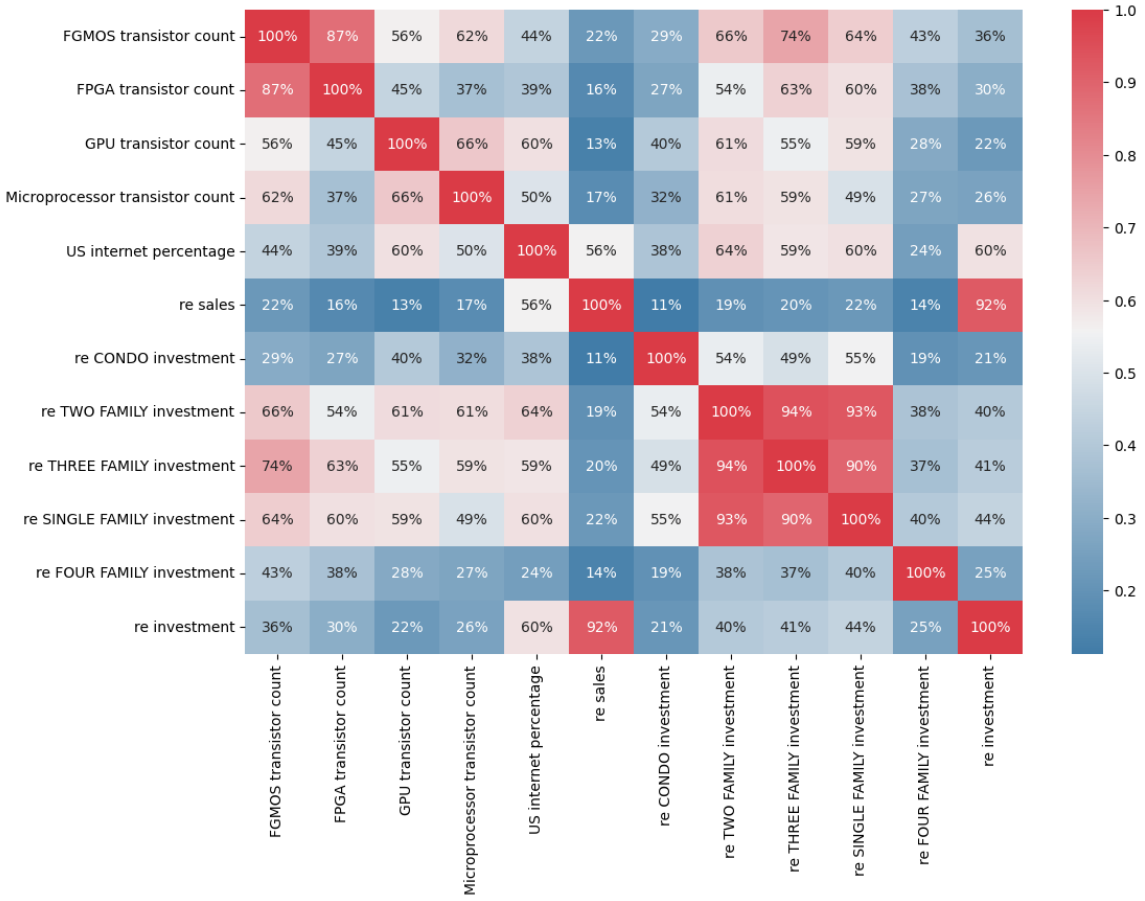

Lo primero que se puede observar es que hay una fuerte correlacion interna entre las variables de los bienes raices e internamente entre las variables de la computacion,

pero recordemos que estas correlaciones estan fuera de nuestro interes, solo nos interesan aquellas correlaciones directas entre los bienes raices y la computacion.

Entre los bienes raices y la computacion podemos encontrar que `US internet percentage` tiene una correlacion lineal "aceptable" con `re investment`, `re SINGLE FAMILY investment`, `re THREE FAMILY investment` y `re TWO FAMILY investment`.

`FGMOS transistor count` y `GPU transistor count` tambien tiene correlaciones parecidas a internet aunque en menor medida.

Recordemos que 100% o -100% seria una correlacion perfecta y 0% seria una correlacion nula.

Veamos el grafico de pares para ver que tipo de relaciones encontramos entre los datos, estos pueden ser lineales, polinomicas, etc.

In [ ]:
```
# Quitamos un punto que esta muy alejado del resto, por algun
# motivo no fue removido cuando se aplico el zscore.
computacion_y_bienes_raices = computacion_y_bienes_raices[computacion_y_b
#
pp = sns.pairplot(
    numeric_df,
    x_vars=columns_to_analize_correlation,
    y_vars=columns_to_analize_correlation
    )
```

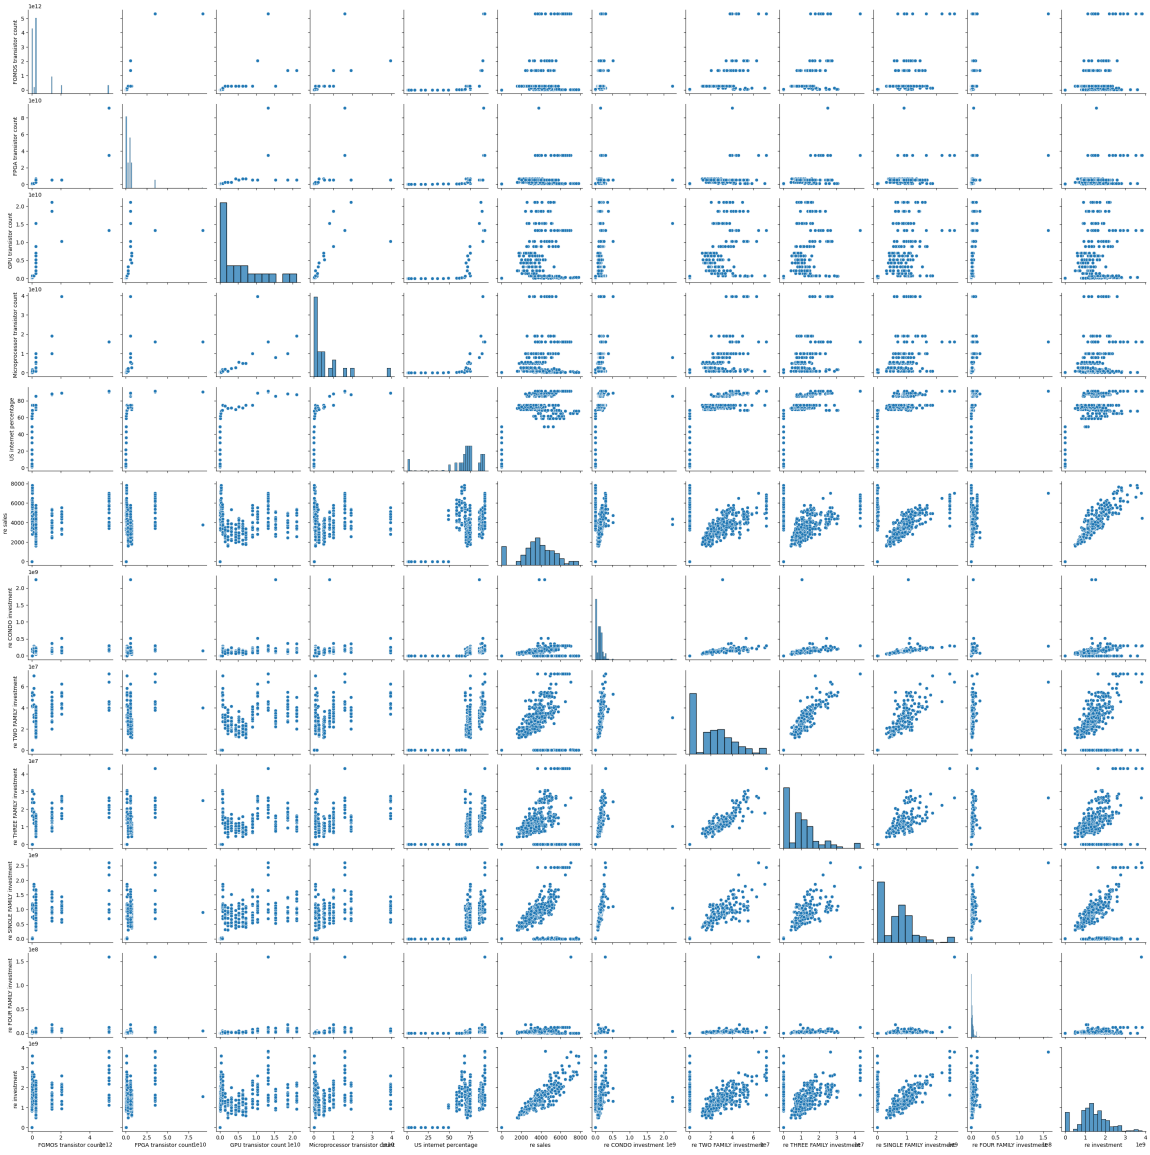

Podemos encontrar visualmente varias correlaciones tanto lineales como polinomicas

Tambien podemos ver correlaciones muy claras entre columnas de bienes raices pero recordemos que esas correlaciones estan fuera de nuestra investigacion.

Veamos en detalle algunas correlaciones encontradas en el pairplot e intentemos hacer algunas proyecciones utilizando regresiones.

- Proyectando regresion lineal de "inversion en casas de una familia" con "cantidad de transistores en GPU"

In [ ]:
```
computacion_y_bienes_raices = computacion_y_bienes_raices.dropna()
computacion_y_bienes_raices = computacion_y_bienes_raices[(computacion_y_
#
X = computacion_y_bienes_raices['US internet percentage'].values.reshape(
y = computacion_y_bienes_raices['re TWO FAMILY investment'].values.reshap
#
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2,
#
lin_reg = LinearRegression()
lin_reg.fit(X_train, y_train)
#
```

```
plt.scatter(X, y, color = "red")
plt.plot(X, lin_reg.predict(X), color = "blue")
plt.title("Internet vs inversion en casas de dos familias")
plt.xlabel("Porcentage de la poblacion con internet")
plt.ylabel("inversion en casas de dos familias (USD)")
plt.grid(color='gray', linestyle='-', linewidth=0.5)
plt.show()
```

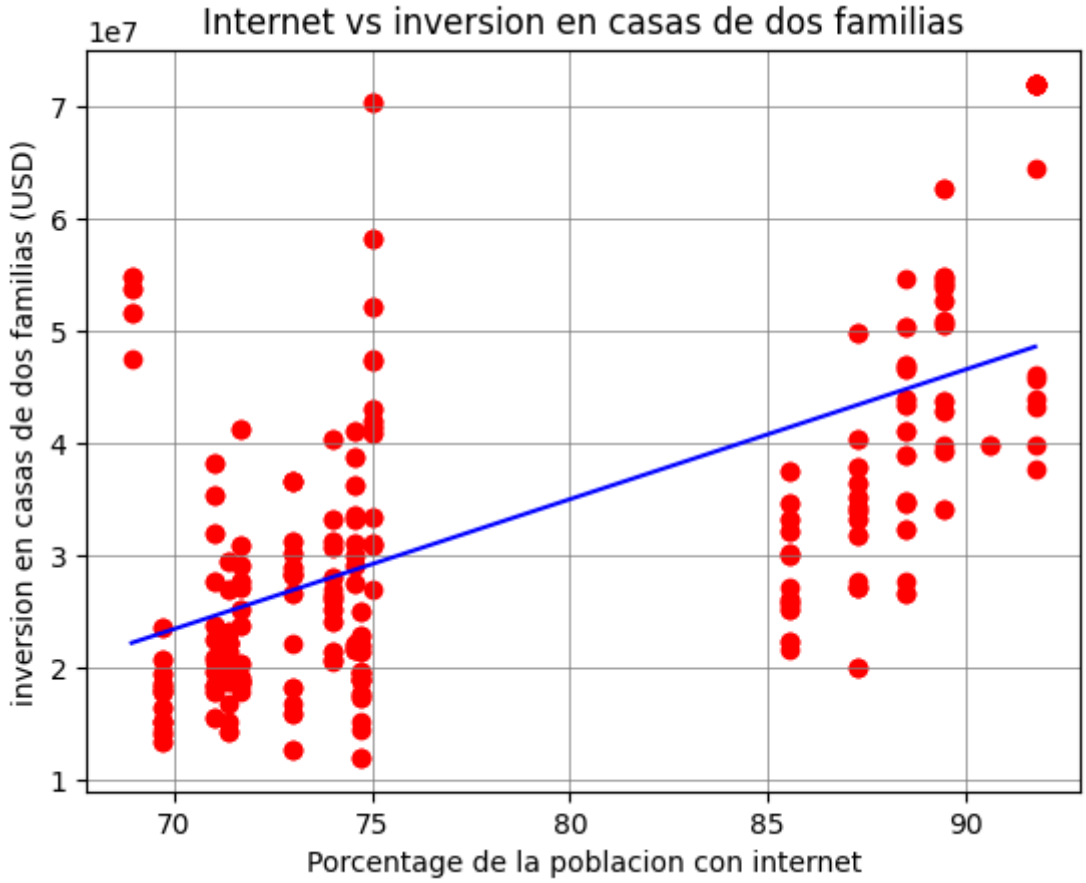

Analizamos el error de la regresion lineal realizada

In [ ]:
```
y_pred = lin_reg.predict(X_test)
#
def imprimir_error(y, y_test, y_pred) -> None:
    """Imprime el error"""
    valor_medio_y = np.mean(y)
    print('Valor medio Y:', valor_medio_y)
    print('Error Absoluto Medio:', metrics.mean_absolute_error(y_test, y_
    print('Error Cuadratico Medio:', metrics.mean_squared_error(y_test, y
    raiz_error_cuadratico_medio = np.sqrt(metrics.mean_squared_error(y_te
    print('Raíz del error cuadrático medio:', raiz_error_cuadratico_medio
    print('Porcentaje de error medio: ', (raiz_error_cuadratico_medio / v
#
imprimir_error(y, y_test, y_pred)
```

```
Valor medio Y: 32567538.174838707
Error Absoluto Medio: 8185483.365339564
Error Cuadratico Medio: 110095246042154.5
Raíz del error cuadrático medio: 10492628.176112717
Porcentaje de error medio:  32.21805750186913 %
```

Podemos observar que la raiz del error cuadratico medio es del 32.21%, lo que nos indica que la regresion lineal es buena.

- Proyectando regresion polinomica en "Cantidad de transistores en el GPU" vs "ventas de bienes raices"

In [ ]:
```
computacion_y_bienes_raices = computacion_y_bienes_raices.dropna()
computacion_y_bienes_raices = computacion_y_bienes_raices.sort_values(by=
#
y = computacion_y_bienes_raices['re sales'].values.reshape(-1,1)
X = computacion_y_bienes_raices['GPU transistor count'].values.reshape(-1
#
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2,
#
lin_reg=LinearRegression()
lin_reg.fit(X_train, y_train)
poly_reg=PolynomialFeatures(degree=6)
X_poly=poly_reg.fit_transform(X)
poly_reg.fit(X_poly,y)
lin_reg2=LinearRegression()
lin_reg2.fit(X_poly,y)
#
plt.scatter(X, y, color = "red")
plt.plot(X,lin_reg2.predict(poly_reg.fit_transform(X)),color='blue')
plt.title('Cantidad de transistores en el GPU vs Cantidad de ventas')
plt.xlabel('Cantidad de transistores en el GPU')
plt.ylabel('Cantidad de ventas')
plt.show()
```

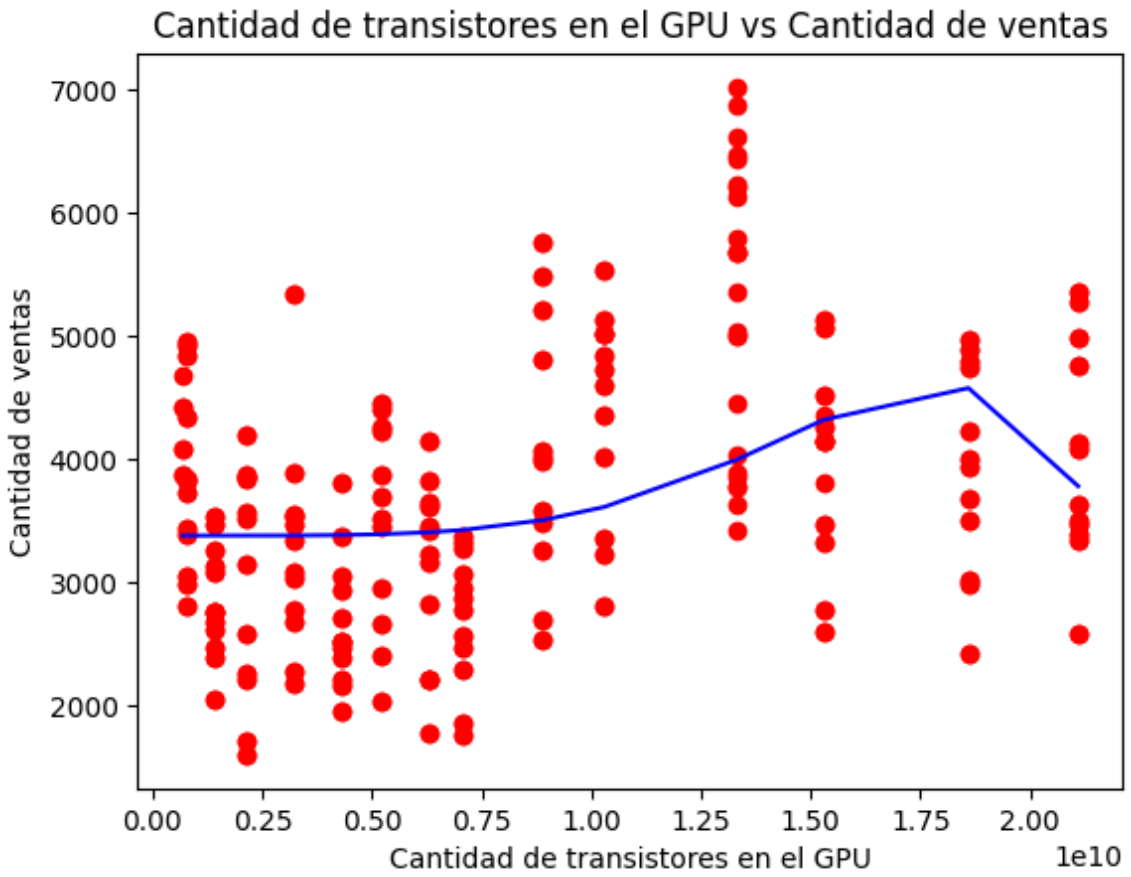

Veamos la precision obtenida con la regresion polinomica

In [ ]:
```
y_pred = lin_reg2.predict(poly_reg.fit_transform(X_test))
imprimir_error(y, y_test, y_pred)
```

```
Valor medio Y: 3626.7360703812315
Error Absoluto Medio: 698.6033794945253
Error Cuadratico Medio: 879516.4190160849
Raíz del error cuadrático medio: 937.8253670146083
Porcentaje de error medio:  25.858660481903417 %
```

Podemos observar que la precision es del 25%, para hacer este tipo de predicciones tambien tenemos a disposicion la regresion con vectores de soporte (SVR).

Este metodo basicamente intenta minimizar la tasa de error dentro de un cierto umbral (limites de decision).

Probemos de utilizar SVR para ver si podemos obtener una mejor precision

In [ ]:
```
computacion_y_bienes_raices = computacion_y_bienes_raices.dropna()
computacion_y_bienes_raices = computacion_y_bienes_raices.sort_values(by=
#
y = computacion_y_bienes_raices['re sales'].values.reshape(-1,1)
X = computacion_y_bienes_raices['GPU transistor count'].values.reshape(-1
#
sc_X = StandardScaler()
sc_y = StandardScaler()
X = sc_X.fit_transform(X)
y = sc_y.fit_transform(y.reshape(-1,1))
#
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2,
#
svr_poly = SVR(kernel="poly", C=100, gamma="auto", degree=5, epsilon=0.1,
svr_poly.fit(X_train, y_train.ravel())
#
plt.scatter(X, y, color = "red")
plt.plot(X, svr_poly.predict(X), color = "blue")
plt.title('Cantidad de transistores en el GPU vs Cantidad de ventas')
plt.xlabel('Cantidad de transistores en el GPU')
plt.ylabel('Cantidad de ventas')
plt.show()
```

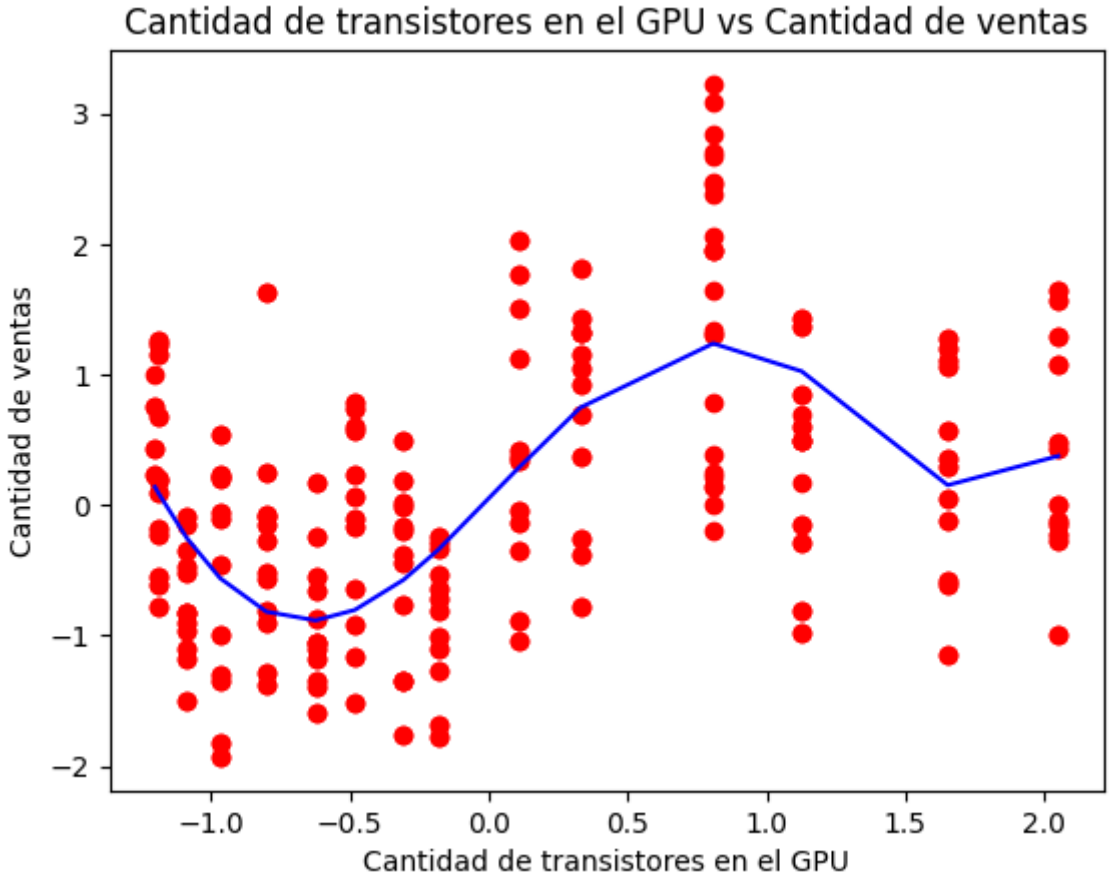

Podemos observar a simple vista que se adapto mejor SVR que utilizando la regresion polinomica, veamos el error de la regresion realizada

In [ ]:
```
y_pred = svr_poly.predict(X_test)
imprimir_error(y, y_test, y_pred)
```

```
Valor medio Y: 2.2920733411616134e-16
Error Absoluto Medio: 0.6977810982267837
Error Cuadratico Medio: 0.701886153732544
Raíz del error cuadrático medio: 0.8377864607001858
Porcentaje de error medio:  3.65514682996836e+17 %
```

Podemos observar que el error cuadratico medio fue muchisimo mas grande que el obtenido anteriormente con la regresion polinomica.

Hasta ahora hemos podido observar con el analisis de las correlaciones y las regresiones, algunos avances en la computacion estan un poco correlacionados con los bienes raices, lo que indica que de alguna estos avances han tenido un impacto aunque sea minimo.

Ahora veamos cuanto han impactado cada una de todos los avances aplicando una regresion lineal multiple y analizando los coeficientes de cada una de las columnas.

- Analizando cuanto fue el impacto en la INVERSION de bienes raices aplicando una regresion lineal multiple

In [ ]:
```
computacion_y_bienes_raices = computacion_y_bienes_raices.dropna()
#
```

```
df = computacion_y_bienes_raices
df = df.dropna()
#
X = mantener_columnas(
    df,
    df.columns[1:-1].tolist()
    )
y = df['re investment'].values
# Removemos nan values
X = X[~np.isnan(X)]
y = y[~np.isnan(y)]
#
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2,
regressor = LinearRegression()
regressor.fit(X_train, y_train)
df = df.drop(columns=['re investment', COLUMNA_FECHA], axis=1)
df = df.T
df = df.index
coeff_df = pd.DataFrame(regressor.coef_, df, columns=['Coefficient'])
coeff_df
```

Out[ ]:

	Coefficient
FGMOS transistor count	-7.941097e-05
FPGA transistor count	4.170304e-03
GPU transistor count	-1.131109e-02
Microprocessor transistor count	-8.597455e-05
US internet percentage	1.163154e+07
re sales	3.242914e+05
re CONDO investment	-5.651820e-01
re TWO FAMILY investment	4.149940e-01
re THREE FAMILY investment	6.214715e+00
re SINGLE FAMILY investment	4.509572e-01
re FOUR FAMILY investment	3.877639e+00

Calculamos el error

In [ ]:

```
y_pred = regressor.predict(X_test)
imprimir_error(y, y_test, y_pred)
```

```
Valor medio Y: 1444213667.1520233
Error Absoluto Medio: 130720147.4548964
Error Cuadratico Medio: 2.638992400642076e+16
Raíz del error cuadrático medio: 162449758.4067787
Porcentaje de error medio:  11.248318867327173 %
```

Podemos observar que obtuvimos una raiz del error cuadratico es medio muy alto con respecto al valor medio Y (11%) aunque sigue siendo aceptable.

De estos coeficientes podemos observar que por cada porcentaje de la poblacion con acceso a internet, la inversion en bienes raices aumenta 1.16x10^7 USD.

- Analizando el impacto en las VENTAS de bienes raices aplicando una regresion lineal multiple

In [ ]:
```
computacion_y_bienes_raices = computacion_y_bienes_raices.dropna()
#
df = computacion_y_bienes_raices
df = df.dropna()
#
X = mantener_columnas(
    df,
    df.columns[1:-1].tolist()
    )
y = df['re sales'].values
# removemos nan values
X = X[~np.isnan(X)]
y = y[~np.isnan(y)]
#
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2,
regressor = LinearRegression()
regressor.fit(X_train, y_train)
df = df.drop(columns=['re sales', COLUMNA_FECHA], axis=1)
df = df.T
df = df.index
coeff_df = pd.DataFrame(regressor.coef_, df, columns=['Coefficient'])
coeff_df
```

Out[ ]:

	Coefficient
FGMOS transistor count	-2.360977e-21
FPGA transistor count	-6.501640e-20
GPU transistor count	-4.131320e-19
Microprocessor transistor count	2.490806e-20
US internet percentage	5.940007e-10
re CONDO investment	1.000000e+00
re TWO FAMILY investment	-3.177873e-17
re THREE FAMILY investment	-6.040222e-16
re SINGLE FAMILY investment	4.535342e-16
re FOUR FAMILY investment	1.268889e-17
re investment	1.016202e-16

Calculamos el error

In [ ]:
```
y_pred = regressor.predict(X_test)
imprimir_error(y, y_test, y_pred)
```

```
Valor medio Y: 3626.7360703812315
Error Absoluto Medio: 3.0731727114787486e-09
Error Cuadratico Medio: 1.522962033313878e-17
Raíz del error cuadrático medio: 3.902514616646398e-09
Porcentaje de error medio:  1.0760404233761012e-10 %
```

Podemos ver que la raiz de error cuadratico medio es bastante (sospechosamente) bajo comparandolo con el valor medio de Y, lo que nos dice que los coeficientes de la regresion lineal multiple son bastante acertados, pero tambien este error excesivamente bajo puede deberse a que la cantidad de datos que quizas puede ser pequeña.

De esta ultima regresion lineal multiple, podemos observar que por cada % de poblacion que utiliza internet, las ventas de bienes raices se incrementan un 5.94e-10, practicamente 0 lo que podemos decir que no impacto en la cantidad de ventas directamente.

Conclusion

En esta investigacion hemos podido observar que los avances en la computacion y los bienes raices tienen algunas correlaciones, hemos podido proyectar regresiones lineales, polinomicas y calcular mediante regresiones lineales multiples cual es el coeficiente con el cual impacta cada avance computacional en las ventas e inversion de bienes raices.

Observamos que el avance en memorias flash y GPUs son las que tienen las mejores correlaciones, y hemos podido observar mediante las regresiones lineales multiples, que el internet es la tecnologia que mas peso tuvo en las inversiones de bienes raices (1.2x10^9 USD por % de poblacion con internet) pero sin embargo, no afecto tanto a las ventas (4.339115e-08 ventas, cero practicamente).

Pero sin embargo se debe tener en cuenta que la industria de bienes raices fue altamente afectada por la burbuja del 2008, por lo cual esto pudo afectar gravemente nuestra investigacion.

Referencias

1. Transistor count datasets (extraido de las tablas) https://en.wikipedia.org/wiki/Transistor_count
2. World Bank Data https://data.worldbank.org/
3. DATA.GOV registros de ventas https://catalog.data.gov/dataset/real-estate-sales-2001-2018
4. Sistema de clasificacion multifamiliar https://en.wikipedia.org/wiki/Multifamily_residential